

Faculté des sciences

Comparaison du filtre de Kalman et des modèles score-driven pour la construction d'indices de prix hédoniques dynamiques

Mémoire présenté en vue de l'obtention du grade académique de
Master [120] en Science des données orientation statistique

Auteur : Zeamari Yassine

Promoteur : Christian Hafner

Lectrice : Anna Kiriliouk

Institut de Statistique, Biostatistique et Sciences Actuarielles

Année académique 2025-2026

Résumé

Ce mémoire s'intéresse à la construction d'indices de prix hédoniques dynamiques à partir de deux modèles à facteur latent : le filtre de Kalman gaussien et le modèle score-driven DCS- t . Un modèle hédonique est estimé sur des données de vins vendus en Belgique, puis les résidus obtenus sont utilisés afin d'étudier l'évolution temporelle des prix. L'analyse repose à la fois sur des simulations Monte Carlo et sur une application empirique. Les résultats montrent que le filtre de Kalman fournit de très bonnes performances dans un cadre gaussien, tandis que le modèle DCS- t se montre plus robuste en présence de chocs ou d'observations extrêmes.

Mots-clés : modèle hédonique dynamique, filtre de Kalman, Dynamic Conditional Score (DCS), DCS- t , modèle espace-état, indice de prix hédonique, simulations Monte Carlo.

Remerciements

Je tiens tout d’abord à exprimer ma profonde gratitude à mon promoteur, le Professeur Christian M. Hafner, pour son encadrement, sa disponibilité et ses précieux conseils tout au long de la réalisation de ce mémoire.

Je tiens également à remercier ma lectrice, Anna Kiriliouk, pour le temps consacré à la lecture de ce mémoire.

Je remercie également l’ensemble des enseignants du Master en Data Science de l’Université catholique de Louvain pour la qualité des enseignements dispensés au cours de cette formation, qui m’ont permis d’acquérir les connaissances nécessaires à la réalisation de ce mémoire.

Mes remerciements s’adressent aussi à ma famille pour son soutien constant, sa patience et ses encouragements tout au long de mon parcours académique.

Table des matières

Résumé	i
Remerciements	ii
Introduction	1
1 Filtre de Kalman multivarié et modèle hédonique dynamique	3
1.1 Modèle hédonique dynamique	3
1.2 Équation d'état	5
1.3 Représentation espace-état	6
1.4 Filtre de Kalman multivarié	7
1.5 Log-vraisemblance multivariée	9
1.6 Estimation des paramètres par maximum de vraisemblance	9
1.7 Procédure de simulation	10
1.8 Résultats de simulation	11
1.8.1 Résultats globaux	11
1.8.2 Impact du nombre d'observations par période N	14
1.8.3 Impact de la taille temporelle T	17
1.9 Limites du modèle gaussien	20
2 Filtre DCS-t et étude comparative	21
2.1 Filtre DCS- t	22

2.1.1	Comportement asymptotique lorsque $\nu \rightarrow \infty$	23
2.2	Design de simulation Monte Carlo	25
2.2.1	Cadre général	25
2.2.2	Paramètres de simulation	25
2.2.3	Mesures de performance	26
2.2.4	Procédure de simulation	26
2.2.5	Dimensions étudiées	26
2.3	Comparaison entre le filtre de Kalman et le modèle DCS- t : paramètres connus	27
2.3.1	Spécification du modèle	27
2.3.2	Calibration du paramètre κ	28
2.3.3	Objectif	28
2.3.4	Résultats et Analyse	29
2.4	Comparaison entre le filtre de Kalman et le modèle DCS- t : paramètres estimés	30
2.4.1	Estimation des paramètres	31
2.4.2	Objectif	32
2.4.3	Résultats et Analyse	33
2.5	Scénario 1 : Cadre gaussien correctement spécifié	38
2.5.1	Résultats et Analyse	39
2.6	Scénario 2 : Estimation gaussienne sous non-gaussianité des erreurs	40
2.6.1	Résultats et Analyse	42
2.7	Scénario 3 : Modélisation d'un régime de crise	45
2.7.1	Résultats et Analyse	47
2.8	Scénario 4 : Modélisation dynamique de l'état latent par un modèle DCS- t	52
2.8.1	Résultats et Analyse	54
3	Application aux données de vin	58
3.1	Description des données	58
3.1.1	Source des données	58
3.1.2	Variables utilisées	59

3.1.3	Statistiques descriptives	60
3.2	Construction du modèle à facteur latent	62
3.3	Analyse des résultats	63
3.4	Scénario de crise	65
3.4.1	Construction du scénario	65
3.4.2	Résultats et analyse	66
3.5	Limites des données	69
Conclusion		70
A Annexes		72
A.1	Démonstration des équations du filtre de Kalman	72
A.2	État stationnaire du filtre de Kalman	75
A.3	Démonstration du modèle DCS- t	76
A.4	Fréquences des variables qualitatives	78
A.5	Résultats de la régression hédonique	79
A.6	Convergence du gain de Kalman	80
A.7	Limite asymptotique DCS pour grands N	82
Bibliographie		83

Introduction

L'analyse des prix est un défi majeur dans les sciences économiques, financières et en application empirique. Par exemple, pour des biens différenciés tels que le vin, le prix s'explique par une combinaison de diverses variables observées (la qualité du produit, sa provenance et ses caractéristiques physiques et chimiques), et d'autres variables cachées non directement observables.

Le modèle hédonique permet justement de relier le prix à ces caractéristiques. Néanmoins, dans sa version classique, il repose sur l'hypothèse que les coefficients ne varient pas dans le temps, ce qui peut être limitant pour analyser les évolutions du marché.

Afin de surmonter cette limitation, ce mémoire propose une extension dynamique du modèle hédonique dans laquelle certains paramètres, en particulier le niveau de prix latent, évoluent au cours du temps. Cette approche s'inscrit dans le cadre des modèles espace-état, permettant de représenter explicitement la dynamique d'un état latent non observé.

Le filtre de Kalman est la méthode classique pour estimer de manière récursive un état latent à partir d'observations bruitées. Sous l'hypothèse d'erreurs gaussiennes, il fournit une estimation optimale en minimisant la variance de l'erreur d'estimation. Cependant, cette hypothèse montre vite ses limites lorsque les données contiennent des outliers ou suivent des distributions à queues épaisses. Pour améliorer la prise en compte de ce type de situations, on s'intéresse également à une approche alternative basée sur les modèles *Dynamic Conditional Score* (DCS) introduits par CREAL, KOOPMAN et LUCAS (2013) et développés par HARVEY (2013), et plus particulièrement au modèle DCS- t , basé sur une distribution de Student- t . Cette spécification permet de mieux prendre en compte les observations atypiques et accroît la robustesse des estimations. L'objectif principal de ce mémoire est donc de comparer les performances du filtre de Kalman et du modèle DCS- t

dans un cadre de modèle hédonique dynamique. Une étude par simulation Monte Carlo est menée afin d'évaluer la précision des estimateurs et d'analyser l'impact des dimensions transversale et temporelle des données.

Cette étude se compose de trois chapitres. Dans un premier temps, on présente le modèle hédonique dynamique et le filtre de Kalman multivarié qui se distinguent par leurs principales caractéristiques déduites à travers des simulations Monte-Carlo. Le deuxième chapitre se consacre au modèle DCS-t ainsi qu'à l'évaluation de ses performances comparativement au filtre de Kalman sous divers scénarios, en particulier lorsque des effets de non-gaussianité ou des chocs surviennent. Enfin, la troisième partie est consacrée à l'application concrète de ces modèles sur des données réelles de vins.

Dans le cadre de la rédaction de ce mémoire, des outils d'intelligence artificielle générative (ChatGPT, Claude.ai) ont été utilisés de manière ponctuelle afin d'assister certaines tâches, notamment la reformulation de certains paragraphes, la correction grammaticale.

Chapitre 1

Filtre de Kalman multivarié et modèle hédonique dynamique

Dans ce chapitre, nous proposons une extension dynamique du modèle hédonique afin de prendre en compte l'évolution temporelle des prix. Contrairement aux modèles statiques, cette approche permet de capturer les variations du marché au cours du temps à travers un coefficient latent β_t .

L'approche est basée sur un modèle espace-état dans lequel la relation entre l'observation et l'état latent non-observable est modélisée en tant que processus évolutif temporel. Dans ce contexte, le filtre de Kalman permet d'estimer l'état latent à partir des observations.

On commence par présenter le modèle, puis les équations du filtre de Kalman dans le cas multivarié. Ensuite, on explique comment les paramètres sont estimés par maximum de vraisemblance. Enfin, une étude de simulation permet d'évaluer les performances du modèle, notamment en fonction des dimensions N et T .

1.1 Modèle hédonique dynamique

Le modèle hédonique fait partie d'une approche classique en économie qui consiste à décomposer le prix d'un bien en fonction de ses caractéristiques observables. Cette idée n'est pas nouvelle : elle apparaît déjà dans les travaux de WAUGH (1928) et COURT (1939), avant d'être développée plus en profondeur par GRILICHES (1961). Par la suite, ROSEN (1974) a proposé un cadre théorique plus structuré, en introduisant notamment la notion de marchés implicites, qui permet de mieux comprendre comment les différentes

caractéristiques d'un bien influencent son prix.

Dans ce mémoire, nous prolongeons cette approche en la plaçant dans un cadre dynamique et multivarié. Cela permet de suivre plus finement l'évolution des prix dans le temps, tout en faisant apparaître un effet commun, non observable, qui agit sur l'ensemble des biens.

À chaque date $t = 1, \dots, T$, on observe un vecteur de logarithme du prix :

$$\mathbf{Y}_t = \begin{pmatrix} Y_{1t} \\ \vdots \\ Y_{Nt} \end{pmatrix} \in R^N,$$

ainsi qu'une matrice de caractéristiques :

$$\mathbf{X}_t = \begin{pmatrix} X_{1t}^\top \\ \vdots \\ X_{Nt}^\top \end{pmatrix} \in R^{N \times p}.$$

Le modèle hédonique s'écrit alors :

$$\boxed{\mathbf{Y}_t = \mathbf{X}_t \alpha + \mathbf{1}_N \beta_t + v_t,}$$

où :

- $\alpha \in R^p$ est le vecteur de paramètres associés aux caractéristiques ;
- $\mathbf{1}_N$ est un vecteur colonne de dimension N rempli de uns ;
- $v_t \in R^N$ est un vecteur d'erreurs idiosyncratiques.
- Le terme β_t représente l'évolution globale des prix à la date t , indépendamment des caractéristiques propres à chaque bien. Il capte ainsi la tendance générale du marché, commune à l'ensemble des biens observés. Dans cette perspective, β_t peut être interprété comme un indice hédonique dynamique permettant de suivre l'évolution des prix au cours du temps.

En retirant l'effet des caractéristiques observables, les données peuvent être réécrites sous la forme :

$$\boxed{\mathbf{z}_t = \mathbf{Y}_t - \mathbf{X}_t \alpha = \mathbf{1}_N \beta_t + v_t,}$$

cette écriture met en évidence qu'une fois les effets individuels pris en compte, il subsiste un effet commun β_t , partagé par tous les biens, ainsi qu'un terme d'erreur. Elle correspond

à l'équation d'observation du modèle espace-état.

1.2 Équation d'état

Afin d'introduire une dynamique temporelle dans l'effet latent, on modélise β_t comme un processus autorégressif d'ordre 1 :

$$\beta_t = \phi\beta_{t-1} + \xi_t,$$

où ξ_t est un bruit gaussien :

$$\xi_t \sim \mathcal{N}(0, \sigma_\xi^2),$$

et où $|\phi| \leq 1$. Cette spécification offre une grande flexibilité, puisqu'elle permet de décrire plusieurs types de dynamiques pour β_t .

Lorsque $|\phi| < 1$, le processus est stationnaire et β_t fluctue autour d'un niveau moyen.

En revanche, lorsque $\phi = 1$, le modèle devient une marche aléatoire :

$$\beta_t = \beta_{t-1} + \xi_t,$$

ce qui veut dire, concrètement, que les chocs s'accumulent au fil du temps. Il n'y a plus de mécanisme de retour vers une valeur moyenne, et le processus peut dériver progressivement. Ce type de comportement est d'ailleurs assez proche de ce que l'on observe pour les prix dans la pratique.

Dans ce cas, β_t représente la tendance générale du marché, commune à tous les biens. Le terme ξ_t peut alors être vu comme un choc global, qui affecte l'ensemble des biens en même temps. Sa variance σ_ξ^2 donne une indication de l'ampleur de ces fluctuations, autrement dit de la volatilité du marché.

Quant aux erreurs d'observation v_t , elles reflètent les fluctuations individuelles de chaque bien, autrement dit la volatilité idiosyncratique propre à chaque actif.

Contrairement à une approche à effets fixes, où l'on estime un effet différent à chaque période sans lien entre eux, la spécification retenue introduit ici une continuité dans le temps. Les valeurs successives de β_t sont liées, ce qui permet de mieux suivre l'évolution du marché et d'éviter des variations trop erratiques. Cette idée est proche des modèles à effets aléatoires dynamiques (voir BOCART et HAFNER (2015b)), qui permettent généralement d'obtenir des estimations plus stables.

Nous n'observons pas directement β_t , il faut utiliser des méthodes de filtrage pour

l'estimer. Ici, nous travaillons principalement avec le filtre de Kalman, tout en testant le modèle DCS comme une piste plus robuste aux valeurs extrêmes.

1.3 Représentation espace-état

Le modèle peut être formulé sous la forme d'un système espace-état, composé d'une équation d'observation et d'une équation d'état.

Équation d'observation

Le vecteur des observations à la date t s'écrit :

$$\mathbf{z}_t = \mathbf{1}_N \beta_t + v_t,$$

où $\mathbf{z}_t \in R^N$ est le vecteur des observations, $\mathbf{1}_N$ est un vecteur de dimension N composé de 1, et v_t est un vecteur d'erreurs d'observation.

On suppose que :

$$v_t \sim \mathcal{N}(0, \sigma_v^2 I_N).$$

Équation d'état

La dynamique de l'état latent est donnée par :

$$\beta_t = \beta_{t-1} + \xi_t,$$

avec

$$\xi_t \sim \mathcal{N}(0, \sigma_\xi^2).$$

Interprétation

Dans cette représentation, l'équation d'observation relie les données observées à l'état latent commun, tandis que l'équation d'état décrit l'évolution temporelle de cet état. Cette formulation se prête naturellement à l'utilisation du filtre de Kalman. Celui-ci permet d'estimer progressivement l'état latent β_t à partir des observations $\mathbf{z}_t$, en mettant à jour l'information au fur et à mesure.

1.4 Filtre de Kalman multivarié

Le filtre de Kalman, introduit par KALMAN (1960), constitue une méthode fondamentale pour l'estimation réursive d'états latents dans les modèles linéaires gaussiens. Son extension au cadre continu a été proposée par KALMAN et BUCY (1961).

Aujourd'hui, le filtre de Kalman est très présent en économétrie et en finance, notamment dans les modèles espace-état. S'il est autant utilisé, c'est en grande partie grâce à ses propriétés optimales sous hypothèse gaussienne HARVEY (1989) et DURBIN et KOOPMAN (2012).

Dans le cadre du modèle espace-état introduit précédemment, les équations du filtre s'écrivent comme suit :

Étape de prédiction

$$\beta_{t|t-1} = \beta_{t-1|t-1}, \quad (1.1)$$

$$P_{t|t-1} = P_{t-1|t-1} + \sigma_\xi^2. \quad (1.2)$$

Cette étape consiste à prévoir l'état latent à la date t à partir de l'information disponible jusqu'à la date $t - 1$. L'incertitude augmente en raison du bruit d'état σ_ξ^2 .

Étape de mise à jour (voir la démonstration en Annexe A.1)

$$\mathbf{v}_t = \mathbf{z}_t - \mathbf{1}_N \beta_{t|t-1}, \quad \mathbf{v}_t \in R^{N \times 1}, \quad (1.3)$$

$$S_t = \mathbf{1}_N P_{t|t-1} \mathbf{1}_N^\top + \sigma_v^2 I_N, \quad S_t \in R^{N \times N}, \quad (1.4)$$

$$K_t = P_{t|t-1} \mathbf{1}_N^\top S_t^{-1} = \frac{P_{t|t-1}}{\sigma_v^2 + N P_{t|t-1}} \mathbf{1}_N^\top, \quad K_t \in R^{1 \times N}, \quad (1.5)$$

$$\beta_{t|t} = \beta_{t|t-1} + K_t \mathbf{v}_t, \quad \beta_{t|t} \in R, \quad (1.6)$$

$$P_{t|t} = (1 - K_t \mathbf{1}_N) P_{t|t-1} = \frac{P_{t|t-1} \sigma_v^2}{\sigma_v^2 + N P_{t|t-1}}, \quad P_{t|t} \in R. \quad (1.7)$$




FIGURE 1.1 – Schéma du filtre de Kalman multivarié dans le modèle à facteur commun

Interprétation

Le terme $\mathbf{v}_t$ correspond à l'innovation, c'est-à-dire l'écart entre les observations et leur prévision. Il représente l'information nouvelle apportée par les données à la date t .

La matrice S_t donne une idée de l'incertitude associée à l'innovation, en combinant à la fois celle liée à l'état latent et celle provenant du bruit de mesure.

Le gain de Kalman K_t occupe une place importante. Le gain de Kalman fixe combien l'on tient compte des données fournies par les observations. Si celles-ci sont peu bruitées, le filtre leur fait davantage confiance ; dans le cas contraire, il s'appuie plus fortement sur la dynamique du modèle.

L'estimation $\beta_{t|t}$ résulte ainsi d'un équilibre entre ce qui était anticipé et ce que les données viennent apporter. Après cette mise à jour, la variance $P_{t|t}$ diminue, ce qui traduit simplement le fait que l'incertitude est réduite.

Le Schéma 1.1 illustre le fonctionnement du filtre de Kalman sous forme récursive. On part d'un état de départ, donné par une estimation $\beta_{0|0}$ et une variance $P_{0|0}$.

À chaque période t , le raisonnement se déroule en deux étapes. On commence par utiliser l'information disponible à la période précédente pour former une prévision de l'état, notée $\beta_{t|t-1}$, ainsi que l'incertitude associée $P_{t|t-1}$. Cette prévision reflète simplement ce que le modèle anticipe avant d'observer les nouvelles données. Après cela, une observation est disponible, mais cette observation n'est pas totalement fiable car du bruit l'affecte. Le filtre confronte alors cette observation à la prédiction, ce qui permet d'évaluer l'écart entre les deux, appelé innovation. Cette information montre le niveau auquel il faut ajuster la prédiction. On ajuste avec le gain de Kalman. Le gain de Kalman règle l'importance donnée à l'observation et à celle du modèle. L'état se met à jour en réunissant ces deux

sources d'information. Cela donne une estimation plus précise $\beta_{t|t}$ et réduit l'incertitude $P_{t|t}$. On recommence ce processus à chaque période. On améliore la qualité de l'estimation au fur et à mesure que l'on ajoute de nouvelles données.

1.5 Log-vraisemblance multivariée

Dans le cadre gaussien, l'innovation du filtre de Kalman peut être décrite à partir du résidu entre les observations et la prédiction :

$$\mathbf{v}_t \sim \mathcal{N}(0, S_t),$$

autrement dit, les observations $\mathbf{z}_t$, conditionnellement à l'information disponible jusqu'à la date $t - 1$, suivent une loi normale multivariée. La densité conditionnelle s'écrit alors :

$$f(\mathbf{z}_t | \mathcal{F}_{t-1}) = \frac{1}{(2\pi)^{N/2} |S_t|^{1/2}} \exp \left(-\frac{1}{2} \mathbf{v}_t^\top S_t^{-1} \mathbf{v}_t \right).$$

En prenant le logarithme, on obtient la contribution à la log-vraisemblance à la date t :

$$\ell_t = -\frac{1}{2} \left[N \log(2\pi) + \log |S_t| + \mathbf{v}_t^\top S_t^{-1} \mathbf{v}_t \right].$$

La log-vraisemblance totale est ensuite obtenue en sommant ces contributions sur l'ensemble des périodes :

$$\mathcal{L}(\sigma_\xi^2, \sigma_v^2) = \sum_{t=1}^T \ell_t.$$

Elle dépend des paramètres σ_ξ^2 et σ_v^2 à travers les quantités $P_{t|t-1}$, S_t et $\mathbf{v}_t$, qui sont calculées de manière récursive à l'aide du filtre de Kalman.

1.6 Estimation des paramètres par maximum de vraisemblance

Les paramètres du modèle σ_ξ^2 et σ_v^2 , sont estimés à partir de la log-vraisemblance associée aux innovations du filtre de Kalman.

L'idée consiste à choisir les valeurs des paramètres qui rendent les observations les plus

plausibles au sens du modèle. On obtient ainsi les estimateurs définis par :

$$(\hat{\sigma}_\xi^2, \hat{\sigma}_v^2) = \arg \max_{\sigma_\xi^2, \sigma_v^2} \mathcal{L}(\sigma_\xi^2, \sigma_v^2).$$

L'absence de solution analytique conduit à recourir à des méthodes numériques pour l'estimation des paramètres. Dans ce travail, l'algorithme L-BFGS-B (*Limited-memory Broyden-Fletcher-Goldfarb-Shanno with Bounds*) est utilisé NOCEDAL et WRIGHT (2006). Il repose sur une approximation itérative de la matrice hessienne à partir du gradient tout en permettant d'imposer des contraintes sur les paramètres, afin de converger vers un optimum.

1.7 Procédure de simulation

La procédure de simulation Monte Carlo se déroule comme suit :

Algorithm 1 Simulation Monte Carlo

```

for  $m = 1$  to  $MC$  do
  Initialiser  $\beta_0 = 0$ 
  for  $t = 1$  to  $T$  do
    Générer  $\xi_t \sim \mathcal{N}(0, \sigma_\xi^2)$ 
     $\beta_t = \beta_{t-1} + \xi_t$ 
    Générer  $v_t \sim \mathcal{N}(0, \sigma_v^2 I_{N_t})$ 
     $z_t = \mathbf{1}_{N_t} \beta_t + v_t$ 
  end for
  Estimer  $(\sigma_\xi^2, \sigma_v^2)$  par maximum de vraisemblance
  Appliquer le filtre de Kalman avec les paramètres considérés
  Obtenir  $\hat{\beta}_t$ 
  Calculer les erreurs d'estimation
  Calculer la MSE, le biais et la variance pour la simulation  $m$ 
end for
Moyenne des résultats sur les  $MC$  simulations

```

1.8 Résultats de simulation

Cette section présente les résultats de l'étude Monte Carlo pour le filtre de Kalman. Les performances sont évaluées à l'aide de la MSE, ainsi que de sa décomposition en biais et variance.

1.8.1 Résultats globaux

Paramètres de simulation

Les simulations sont réalisées à partir des paramètres suivants :

- horizon temporel : $T = 200$ périodes,
- nombre d'observations par période : $N \in [20, 60]$,
- condition initiale : $\beta_0 = 0, P_0 = 10^6$,
- variance du bruit d'observation : $\sigma_v^2 = 1.0$,
- variance du bruit d'état : $\sigma_\xi^2 = 0.04$.




FIGURE 1.2 – Trajectoire simulée de l'état latent β_t et estimation par le filtre de Kalman (MSE = 0.0183).

TABLE 1.1 – Statistiques Monte Carlo (MC = 500) : biais, variance et MSE de l'estimateur $\hat{\beta}_t$ obtenu par le filtre de Kalman.

Métrique	Valeur
Bias	0.000928
Variance	0.018264
MSE	0.018265

La Figure 1.2 montre que l'estimation suit de près la dynamique de la trajectoire réelle, ce qui illustre la capacité du filtre à extraire efficacement le signal latent à partir d'observations bruitées.

Les métriques présentées dans le Tableau 1.1 sont obtenues à partir des simulations Monte Carlo en exploitant la distribution empirique des estimateurs $\hat{\beta}_t$.

Pour chaque date t et chaque réplication $m = 1, \dots, MC$, on dispose d'une estimation $\hat{\beta}_t^{(m)}$ ainsi que de la valeur vraie $\beta_t^{(m)}$.

Biais

Le biais global est calculé comme la moyenne des erreurs d'estimation :

$$\widehat{\text{Bias}} = \frac{1}{MC \times T} \sum_{m=1}^{MC} \sum_{t=1}^T \left(\hat{\beta}_t^{(m)} - \beta_t^{(m)} \right).$$

Variance

La variance mesure la dispersion des estimateurs autour de leur moyenne empirique :

$$\widehat{\text{Var}} = \frac{1}{MC \times T - 1} \sum_{m=1}^{MC} \sum_{t=1}^T \left(\hat{\beta}_t^{(m)} - \bar{\beta} \right)^2,$$

où

$$\bar{\beta} = \frac{1}{MC \times T} \sum_{m=1}^{MC} \sum_{t=1}^T \hat{\beta}_t^{(m)}.$$

Erreur quadratique moyenne

La MSE est définie comme :

$$\widehat{\text{MSE}} = \frac{1}{MC \times T} \sum_{m=1}^{MC} \sum_{t=1}^T \left(\hat{\beta}_t^{(m)} - \beta_t^{(m)} \right)^2.$$

On constate que le biais est extrêmement faible, ce qui indique que le filtre de Kalman est pratiquement non biaisé dans ce cadre.

L'erreur est principalement due à la variance de l'estimateur. Cette observation est confirmée par le fait que la MSE est presque entièrement expliquée par la variance, le biais étant négligeable :

$$\text{MSE} \approx \text{Var}(\hat{\beta}_t).$$




FIGURE 1.3 – Évolution du biais, de la variance et de la MSE de l'estimateur $\hat{\beta}_t$ en fonction du temps.

Les métriques représentées sur la Figure 1.3 sont calculées empiriquement à partir des simulations Monte Carlo. Pour chaque date t , elles sont définies par :

$$\widehat{\text{Bias}}_t = \frac{1}{MC} \sum_{m=1}^{MC} \left(\hat{\beta}_t^{(m)} - \beta_t^{(m)} \right),$$

$$\widehat{\text{Var}}_t = \frac{1}{MC - 1} \sum_{m=1}^{MC} \left(\hat{\beta}_t^{(m)} - \bar{\beta}_t \right)^2,$$

$$\widehat{\text{MSE}}_t = \frac{1}{MC} \sum_{m=1}^{MC} \left(\hat{\beta}_t^{(m)} - \beta_t^{(m)} \right)^2,$$

où $\bar{\beta}_t$ désigne la moyenne empirique des estimations à la date t .

Le biais reste globalement très proche de zéro sur l'ensemble des périodes, ce qui montre que le filtre de Kalman ne présente pas de biais particulier dans ce cadre.

La variance reste globalement stable au fil du temps, avec seulement de petites variations, ce qui montre que l'incertitude sur l'état latent est bien contrôlée.

Au début de la période, la MSE peut être légèrement plus élevée, en raison de l'incertitude initiale associée à la condition de départ du filtre. Elle diminue ensuite rapidement et se stabilise.

TABLE 1.2 – Statistiques Monte Carlo (MC = 500) pour l'estimation des paramètres σ_ξ^2 et σ_v^2 .

Paramètre	Valeur vraie	Moyenne	Biais	Variance	MSE
σ_ξ^2	0.04	0.039592	-0.000408	0.000045	0.000045
σ_v^2	1.00	0.998906	-0.001094	0.000252	0.000253

Le Tableau 1.2 montre que les moyennes empiriques des estimateurs sont très proches des valeurs vraies, tant pour σ_ξ^2 que pour σ_v^2 , ce qui indique que les estimateurs obtenus par maximum de vraisemblance sont globalement non biaisés.

Les biais observés sont en effet très faibles, les variances des estimateurs restent relativement faibles, ce qui traduit une bonne précision de l'estimation.

1.8.2 Impact du nombre d'observations par période N

La Figure 1.4 illustre l'évolution de la MSE associée à l'estimation de l'état latent β_t en fonction de la taille du panel N .

On voit que la MSE diminue à mesure que le nombre d'observations par période augmente. Quand N est faible, elle reste assez élevée, ce qui traduit une incertitude importante dans l'estimation de l'état latent. En augmentant N , la MSE baisse rapidement, puis finit par se stabiliser.

Afin de justifier mathématiquement ce comportement, on analyse l'évolution de la covariance filtrée $P_{t|t}$ (1.7).

$$P_{t|t} = \frac{\sigma_v^2 P_{t|t-1}}{\sigma_v^2 + N P_{t|t-1}},$$

cette expression peut également s'écrire sous la forme

$$P_{t|t} = \left(P_{t|t-1}^{-1} + \frac{N}{\sigma_v^2} \right)^{-1}.$$

Dans le cadre du filtre de Kalman, la covariance filtrée est définie comme :

$$P_{t|t} = E \left[(\beta_t - \hat{\beta}_{t|t})^2 \right],$$

ce qui met explicitement en évidence le rôle de la dimension du panel N .

En particulier, lorsque N augmente, la variance d'estimation $P_{t|t}$ diminue. De plus, pour des valeurs élevées de N , on obtient l'approximation

$$P_{t|t} \approx \frac{\sigma_v^2}{N},$$

cette propriété théorique est cohérente avec les résultats obtenus par simulation Monte Carlo, où l'on observe une diminution de la MSE empirique lorsque la taille du panel augmente.




FIGURE 1.4 – Évolution de la MSE de l'estimation de β_t en fonction de la taille du panel N (MC = 500).


Le Tableau 1.3 montre que pour toutes les configurations, les estimations sont très proches des valeurs vraies ($\sigma_\xi^2 = 0.04$ et $\sigma_v^2 = 1$).

Ce résultat s'explique par le fait que l'information utilisée pour estimer les paramètres provient principalement de la dimension temporelle T . Même lorsque la taille du panel N est faible, une grande dimension temporelle T permet d'obtenir une estimation précise des paramètres. En effet, la log-vraisemblance agrège l'information sur l'ensemble des périodes, ce qui compense le faible nombre d'observations à chaque date.

La Figure 1.5 montre que les distributions sont centrées autour de la valeur vraie $\sigma_v^2 = 1$, ce qui confirme l'absence de biais de l'estimateur. Lorsque N augmente, les distributions deviennent progressivement plus concentrées autour de la valeur vraie. Cela traduit une diminution de la variance de l'estimateur et donc une amélioration de sa précision.

N	$\hat{\sigma}_\xi^2$	$\hat{\sigma}_v^2$
5	0.0399	1.0001
10	0.0396	0.9992
20	0.0400	0.9988
40	0.0403	1.0000
60	0.0402	0.9992
100	0.0402	0.9996
120	0.0398	1.0002
150	0.0396	0.9997
200	0.0399	1.0002

TABLE 1.3 – Stabilité des estimations des paramètres σ_ξ^2 et σ_v^2 en fonction de la taille du panel N (MC = 500, $T = 200$).


 FIGURE 1.5 – Impact de N sur l'estimation de σ_v^2 .

1.8.3 Impact de la taille temporelle T

Afin d'évaluer l'impact de la longueur de l'échantillon temporel sur la qualité de l'estimation de l'état latent, nous réalisons une étude de Monte Carlo. Pour différentes valeurs de T .

T	Bias	Var	MSE
20	0.0015	0.01283	0.01283
50	0.0005	0.01274	0.01274
100	-0.0001	0.01264	0.01265
150	-0.0002	0.01269	0.01269
200	0.0002	0.01260	0.01260
300	0.0001	0.01267	0.01267
400	0.0001	0.01264	0.01264
600	0.0002	0.01265	0.01265
800	0.0001	0.01267	0.01267
1000	-0.0002	0.01266	0.01266

 TABLE 1.4 – Impact de la dimension temporelle T sur les performances de l'estimation de β_t pour un panel de taille fixée $N = 60$ (MC = 500).

Selon Le Tableau 1.4, On observe que la MSE diminue légèrement pour des petites

valeurs de T , puis se stabilise rapidement autour d'un niveau constant lorsque T augmente. L'augmentation de T n'entraîne pas d'amélioration significative de la précision de l'estimation de β_t .

D'un point de vue théorique, lorsque T devient grand, le filtre atteint un régime stationnaire dans lequel la covariance converge vers une constante, telle que :

$$P_{t|t} = P_{t-1|t-1} \rightarrow P_{\infty|\infty}.$$

En utilisant les équations de prédiction (1.2) et de mise à jour du filtre de Kalman (1.7), on obtient la relation stationnaire (voir la Démonstration en A.2) :

$$P_{\infty|\infty} = \frac{-\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_{\xi}^2\sigma_v^2}{N}}}{2}.$$

Le gain stationnaire du filtre de Kalman est donné par :

$$K_{\infty} = \frac{\frac{\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_{\xi}^2\sigma_v^2}{N}}}{2}}{\sigma_v^2 + N \cdot \frac{\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_{\xi}^2\sigma_v^2}{N}}}{2}} \mathbf{1}_N^{\top},$$

ce qui montre que la variance d'estimation converge vers une constante indépendante de T . L'augmentation de T permet uniquement de réduire l'influence des conditions initiales et d'atteindre plus rapidement le régime stationnaire.

T	$\hat{\sigma}_{\xi}^2$ (mean)	$\hat{\sigma}_v^2$ (mean)
20	0.0395	0.9992
50	0.0401	1.0006
100	0.0401	0.9998
150	0.0398	1.0003
200	0.0398	1.0003
300	0.0398	1.0003
400	0.0401	1.0000
600	0.0401	1.0000
800	0.0401	0.9999
1000	0.0400	1.0000


TABLE 1.5 – Impact de la dimension temporelle T sur les estimations moyennes des paramètres σ_{ξ}^2 et σ_v^2 pour un panel de taille fixée $N = 60$ (MC = 500).

Le Tableau 1.5 et la Figure 1.6a montrent que, pour toutes les valeurs de T , les estimations sont très proches des valeurs vraies ($\sigma_{\xi}^2 = 0.04$ et $\sigma_v^2 = 1$), les distributions deviennent progressivement plus concentrées autour de la valeur vraie. Ce qui confirme l'absence de biais des estimateurs.

Contrairement à l'estimation de l'état latent β_t , l'augmentation de T n'affecte pas significativement la moyenne des estimateurs, mais permet de réduire leur dispersion (voir la Figure 1.6b), ce qui améliore leur précision. Ce comportement s'explique par le fait que l'information utilisée pour estimer les paramètres est agrégée sur l'ensemble des périodes via la log-vraisemblance :

$$\mathcal{L} = \sum_{t=1}^T \ell_t.$$

Ainsi, même pour des valeurs modérées de T , les estimateurs sont déjà centrés autour des valeurs vraies, tandis que l'augmentation de T permet principalement de réduire leur variance.



(a) Distribution empirique de $\hat{\sigma}_v^2$ pour différentes valeurs de T ($N = 60$, $MC = 500$). (b) Variance empirique des estimateurs $\hat{\sigma}_\xi^2$ et $\hat{\sigma}_v^2$ en fonction de T .

FIGURE 1.6 – (a) Distribution empirique de $\hat{\sigma}_v^2$ pour différentes valeurs de T . (b) Variance empirique des estimateurs en fonction de T , montrant une décroissance de type $1/T$.

1.9 Limites du modèle gaussien

Le filtre de Kalman donne de bons résultats si les données suivent une distribution gaussienne, mais en réalité, ce n'est pas toujours le cas.

Dans beaucoup de situations, les données peuvent contenir des valeurs extrêmes ou avoir des queues épaisses. Dans ce cas, la loi normale a tendance à sous-estimer la fréquence de ces observations atypiques. Le filtre réagit parfois trop fortement à ces valeurs. Cela complique l'estimation de l'état latent et le modèle devient moins fiable. Pour comprendre ces situations, il faut regarder plusieurs modèles. La section suivante présente un modèle qui utilise la distribution de Student-t. Ce modèle aide à mieux prendre en compte les valeurs extrêmes.

Chapitre 2

Filtre DCS- t et étude comparative

Dans le chapitre précédent, le filtre de Kalman a été introduit comme une méthode standard pour estimer un état latent dans un cadre gaussien. Mais cette méthode suppose que les erreurs suivent une loi normale. Ce n'est pas toujours le cas quand les données comportent des valeurs très élevées ou montrent des queues épaisses.

Afin de pallier cette limitation, ce chapitre introduit le modèle score-driven (DCS- t), qui repose sur l'utilisation du score de la log-densité conditionnelle pour faire évoluer l'état latent. Cette approche permet d'intégrer explicitement la distribution des erreurs dans la dynamique du modèle et d'améliorer la robustesse face aux observations atypiques.

Dans un premier temps, nous revenons sur la formulation du filtre DCS- t et sur l'interprétation de ses différentes composantes. Nous mettons en évidence les mécanismes de robustesse apportés par la loi de Student- t , puis nous examinons brièvement certaines propriétés du modèle, en particulier son comportement lorsque le nombre de degrés de liberté augmente.

Dans un second temps, nous mettons en place une étude de simulation Monte Carlo afin de comparer les performances du filtre de Kalman et du modèle DCS- t . Plusieurs scénarios sont considérés, permettant d'évaluer l'impact de différentes dimensions telles que la taille du panel, le degré de non-gaussianité des erreurs, ou encore la présence de régimes de crise.

Les modèles sont évalués à l'aide de la MSE, du biais et de la variance, afin de mieux comprendre le compromis entre précision et robustesse selon les différents contextes étudiés.

2.1 Filtre DCS- t

Le modèle *score-driven* a été introduit par CREAL, KOOPMAN et LUCAS (2013). Il permet d'obtenir une dynamique robuste aux observations extrêmes, en intégrant explicitement la forme de la distribution conditionnelle HARVEY (2013) et LIN et al. (2025).

Le filtre DCS- t est défini par les équations suivantes (voir la démonstration en Annexe A.3) :

$$\mathbf{e}_t = \mathbf{z}_t - \mathbf{1}_N \beta_t, \quad (2.1)$$

$$\beta_t = \beta_{t-1} + \kappa u_{t-1}, \quad (2.2)$$

$$u_t = \frac{1}{\omega_t} \frac{\nu + N}{\nu} \frac{1}{\sigma_v^2} \mathbf{1}_N' \mathbf{e}_t, \quad (2.3)$$

$$\omega_t = 1 + \frac{\mathbf{e}_t' \mathbf{e}_t}{\nu \sigma_v^2}. \quad (2.4)$$

Interprétation

Ces équations décrivent une dynamique d'état *score-driven*, dans laquelle l'évolution de la variable latente est directement pilotée par l'information contenue dans les observations.

— Équation d'observation

Le vecteur d'observations s'écrit :

$$\mathbf{z}_t = \mathbf{1}_N \beta_t + v_t, \quad v_t \sim t_\nu(0, \sigma_v^2 I_N).$$

La loi de Student- t sert à mieux représenter les queues épaisses. Ce modèle supporte mieux les valeurs extrêmes que le modèle gaussien.

Le paramètre σ_v^2 ne correspond pas directement à la variance des erreurs, mais à un paramètre d'échelle. En effet, lorsque $\nu > 2$, la matrice de variance-covariance est donnée par :

$$\text{Var}(v_t) = \sigma_v^2 \frac{\nu}{\nu - 2} I_N.$$

— Équation d'état (2.2)

Contrairement au filtre de Kalman qui traite l'innovation comme un simple bruit extérieur, dans le modèle DCS l'innovation dépend directement des observations passées à travers le score. Le paramètre $\kappa > 0$ détermine à quel point l'état latent est mis à jour. Avec un κ élevé, le modèle devient très réactif aux nouvelles données,

mais ça peut aussi faire fluctuer davantage l'état. À l'inverse, quand κ est plus petit, l'évolution de l'état se fait de manière plus lente et plus stable.

— **Score**

Le terme u_t (2.3) correspond au score de la log-densité conditionnelle par rapport à β_t . Il agrège l'information contenue dans les résidus et détermine à la fois la direction et l'intensité de l'ajustement de l'état latent.

Cette structure introduit des mécanismes importants :

- Le facteur $\frac{\nu+N}{\nu}$ amplifie le score lorsque ν est faible, ce qui correspond à des distributions à queues épaisses.
- L'expression de ω_t (2.4) dépend de $\mathbf{e}_t' \mathbf{e}_t$ et joue un rôle direct dans l'actualisation de l'état latent. Dans le cas où les erreurs sont élevées, alors ω_t est également élevé. En fait, une augmentation de ω_t signifie que le score sera moins pris en compte. En d'autres termes, les observations aberrantes auront moins d'influence sur l'estimation de l'état latent. Cela assure la stabilité du modèle.
- Une autre propriété importante du score concerne son comportement dans le temps. Lorsque le modèle est correctement spécifié, le score vérifie la propriété de suite de différences de martingale (*Martingale Difference Sequence*, MDS) :

$$E(u_t \mid \mathcal{F}_{t-1}) = 0,$$

où $\mathcal{F}_{t-1}$ représente l'ensemble des informations disponibles jusqu'à la période précédente. Autrement dit, le score ne contient pas d'information prévisible à partir du passé. Par conséquent, il présente théoriquement une autocorrélation nulle aux retards non nuls. En pratique, une fonction d'autocorrélation (ACF) estimée proche de zéro indique que la dynamique du modèle capture correctement l'information temporelle contenue dans les données.

2.1.1 Comportement asymptotique lorsque $\nu \rightarrow \infty$

Lorsque le nombre de degrés de liberté augmente, la loi de Student- t se rapproche progressivement d'une distribution gaussienne. Dans cette situation, les propriétés de robustesse associées aux queues épaisses disparaissent.

En particulier, quand on s'approche du cadre gaussien, les termes de correction tendent vers 1 :

$$\frac{\nu + N}{\nu} \rightarrow 1, \quad \omega_t \rightarrow 1.$$

Le score se simplifie et devient $u_t \rightarrow \frac{1}{\sigma_v^2} \mathbf{1}'_N \mathbf{e}_t$.

La dynamique du modèle DCS s'écrit alors :

$$\beta_t = \beta_{t-1} + \kappa \frac{1}{\sigma_v^2} \mathbf{1}'_N \mathbf{e}_{t-1}.$$

Cette expression est proche de celle du filtre de Kalman, donné par :

$$\beta_t = \beta_{t-1} + K_t \mathbf{v}_t.$$


Même dans cette situation, les deux approches ne se comportent pas exactement de la même manière.

Dans le modèle DCS, l'état latent est mis à jour à partir des observations passées grâce au score. Le paramètre κ sert simplement à contrôler l'intensité de cet ajustement, et il reste fixe tout au long du temps. Le filtre de Kalman utilise les données disponibles à chaque moment. Le filtre de Kalman modifie le gain au fil du temps. Les deux méthodes restent différentes parce que chacun utilise l'information d'une autre façon, même si le contexte ressemble à un cas gaussien.


La Figure 2.1 illustre ce résultat dans le cas $\nu = 10000$ et $N = 100$. Le panneau (a) montre que le gain de Kalman converge rapidement vers une constante proche de $\frac{\kappa}{\sigma_v^2}$. Le panneau (b) montre que les termes correctifs des deux modèles sont très proches, ce qui confirme qu'en régime quasi gaussien, le modèle DCS reproduit un comportement voisin de celui du filtre de Kalman. À l'inverse, lorsque ν diminue, la distribution présente des queues plus épaisses et les écarts entre les termes correctifs des deux modèles deviennent plus importants.

Néanmoins, un léger écart subsiste même en régime quasi gaussien, ce qui rappelle que les deux mécanismes de mise à jour restent distincts. Cet écart dépend notamment de la taille du panel N . En effet, lorsque N est faible, le gain de Kalman est très proche du terme $\frac{\kappa}{\sigma_v^2}$ (voir les figures en Annexe A.6). En revanche, lorsque N augmente, un décalage plus important apparaît.

Ce phénomène s'explique par le fait que le gain stationnaire K_∞ du filtre de Kalman (1.8.3) dépend explicitement de N et tend à diminuer lorsque le nombre d'observations augmente.



(a) Convergence du gain de Kalman.



(b) Comparaison des termes correctifs de KF et DCS.

 FIGURE 2.1 – Comparaison entre le filtre de Kalman et le modèle DCS dans le cas limite quasi gaussien ($\nu = 10000$, $N = 100$).

2.2 Design de simulation Monte Carlo

2.2.1 Cadre général

Dans cette partie, nous expliquons le protocole de simulation Monte Carlo qui permet de comparer les performances du filtre de Kalman et du modèle DCS dans plusieurs situations.

Pour chaque configuration, $MC = 500$ simulations indépendantes sont réalisées. À chaque simulation, on génère une trajectoire de l'état latent β_t , ainsi que les observations associées z_t . Les deux modèles sont ensuite utilisés pour estimer cet état.

2.2.2 Paramètres de simulation

TABLE 2.1 – Paramètres communs de simulation.

Paramètre	Valeur
Nombre de périodes (T)	200
Nombre de simulations (MC)	500
Variance de l'état (σ_ξ^2)	0.04
Variance d'échelle (σ_v^2)	1.0

2.2.3 Mesures de performance

Les modèles ont été évalués avec trois mesures différentes. La MSE mesure l'erreur totale. La variance montre si les estimations restent stables. Le biais indique si le modèle donne en général la bonne réponse.

Dans les scénarios où les paramètres sont estimés, une analyse supplémentaire est menée sur les paramètres eux-mêmes. En particulier, les biais et la variabilité des estimateurs de paramètres sont également étudiés afin d'évaluer la qualité de l'estimation.

2.2.4 Procédure de simulation

Algorithm 2 Simulation Monte Carlo

```

for  $m = 1$  to  $MC$  do
  Générer la trajectoire latente  $\beta_t$ 
  Générer les observations  $\mathbf{z}_t$  selon le scénario considéré
  if scénario avec estimation des paramètres then
    Estimer les paramètres du filtre de Kalman
    Estimer les paramètres du modèle DCS
  end if
  Appliquer le filtre de Kalman
  Appliquer le modèle DCS
  Calculer les erreurs d'estimation de  $\beta_t$  après burn-in
  Calculer la MSE, le biais et la variance pour la simulation  $m$ 
end for
Calculer la moyenne des résultats sur les  $MC$  simulations

```

2.2.5 Dimensions étudiées

Afin d'évaluer le comportement des modèles dans différents contextes, plusieurs dimensions sont étudiées.

TABLE 2.2 – Dimensions étudiées dans les comparaisons.

Comparaison	Paramètre varié
1	Nombre d'individus N
2	Degrés de liberté ν
3	Intensité de crise m
4	Durée de crise L
5	Distribution des erreurs
6	Dynamique de l'état latent

2.3 Comparaison entre le filtre de Kalman et le modèle DCS- t : paramètres connus

Dans cette première partie, les paramètres des deux modèles sont supposés connus. Le filtre de Kalman est appliqué avec les valeurs vraies des paramètres $(\sigma_\xi^2, \sigma_v^2)$, tandis que le modèle DCS- t utilise les valeurs vraies de σ_v^2 et ν . Le paramètre κ n'est pas estimé par maximum de vraisemblance, mais calibré.

2.3.1 Spécification du modèle

La dynamique de l'état latent β_t suit une marche aléatoire gaussienne :

$$\beta_t = \beta_{t-1} + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \sigma_\xi^2).$$

Les observations sont générées à partir du modèle :

$$\mathbf{z}_t = \beta_t \mathbf{1}_N + v_t,$$

où $\mathbf{z}_t \in R^N$ et $\mathbf{1}_N$ est un vecteur de dimension N composé de 1.

Les erreurs d'observation suivent une loi de Student- t :

$$v_{it} \sim t_\nu(0, \sigma_v^2), \quad i = 1, \dots, N.$$

Ce cadre permet d'introduire des observations extrêmes, en particulier lorsque ν est faible.

2.3.2 Calibration du paramètre κ

Dans le cadre du modèle DCS- t , l'innovation de l'état s'écrit :

$$\xi_t = \kappa u_{t-1}.$$

Cela implique que la variance de l'innovation est donnée par :

$$\text{Var}(\xi_t) = \kappa^2 \text{Var}(u_{t-1}).$$

Dans cette première partie, la variance du bruit d'état σ_ξ^2 est supposée connue. Le paramètre κ est alors calibré de façon à respecter la relation :

$$\sigma_\xi^2 = \kappa^2 \text{Var}(u_{t-1}).$$

En pratique, la variance $\text{Var}(u_t)$ est estimée empiriquement à partir de la série des scores :

$$\text{Var}(u_t) \approx \frac{1}{T} \sum_{t=1}^T (u_t - \bar{u})^2.$$

Cette approximation est cohérente avec les propriétés théoriques du score discutées précédemment. En particulier, lorsque le modèle est correctement spécifié, le score se comporte approximativement comme un bruit blanc, ce qui permet d'estimer sa variance à partir de la variance empirique de la série observée.

2.3.3 Objectif

Dans cette partie, l'objectif est d'évaluer les performances des deux méthodes dans un cadre idéal où les paramètres sont supposés connus. Cela permet d'isoler les différences liées aux modèles eux-mêmes, sans introduire d'incertitude liée à l'estimation des paramètres.

2.3.4 Résultats et Analyse

TABLE 2.3 – Comparaison des performances de KF et DCS pour différentes valeurs de N et ν .

N	ν	KF			DCS		
		MSE	Var	Bias	MSE	Var	Bias
5	3	0.1330	0.1330	-0.0015	0.1363	0.1363	0.0006
5	5	0.0973	0.0973	0.0020	0.1263	0.1263	0.0011
5	10	0.0829	0.0829	0.0028	0.1214	0.1214	0.0031
5	20	0.0770	0.0770	0.0000	0.1180	0.1180	0.0002
5	50	0.0737	0.0737	-0.0009	0.1143	0.1143	-0.0014
20	3	0.0587	0.0587	-0.0008	0.0856	0.0856	0.0011
20	5	0.0404	0.0404	0.0021	0.0790	0.0790	0.0031
20	10	0.0341	0.0341	-0.0005	0.0750	0.0750	-0.0008
20	20	0.0310	0.0310	0.0022	0.0714	0.0714	0.0027
20	50	0.0297	0.0297	-0.0007	0.0703	0.0703	-0.0009
40	3	0.0413	0.0413	0.0023	0.0750	0.0749	0.0036
40	5	0.0254	0.0254	0.0007	0.0683	0.0683	-0.0009
40	10	0.0205	0.0205	0.0003	0.0624	0.0624	0.0003
40	20	0.0188	0.0188	0.0000	0.0600	0.0600	-0.0001
40	50	0.0180	0.0180	0.0008	0.0587	0.0587	0.0005
60	3	0.0288	0.0288	0.0012	0.0707	0.0707	0.0010
60	5	0.0189	0.0189	-0.0005	0.0642	0.0642	-0.0018
60	10	0.0151	0.0151	-0.0003	0.0584	0.0584	0.0007
60	20	0.0137	0.0137	-0.0003	0.0552	0.0552	0.0002
60	50	0.0130	0.0130	-0.0003	0.0537	0.0537	0.0001
100	3	0.0192	0.0192	0.0006	0.0665	0.0665	0.0013
100	5	0.0126	0.0126	-0.0003	0.0592	0.0592	-0.0011
100	10	0.0099	0.0099	-0.0002	0.0538	0.0538	-0.0005
100	20	0.0090	0.0090	0.0003	0.0515	0.0515	0.0010
100	50	0.0085	0.0085	-0.0004	0.0492	0.0492	-0.0008

Le Tableau 2.3 présente les résultats en termes d'erreur quadratique moyenne (MSE), de variance et de biais lorsque les paramètres des deux modèles sont supposés connus.

La comparaison des MSE montre que le filtre de Kalman reste globalement plus performant que le modèle DCS dans l'ensemble des configurations.

Cette observation s'explique principalement par le fait que la dynamique de l'état latent est générée selon un modèle linéaire gaussien, exactement conforme à celui supposé par le filtre de Kalman. Dans ce contexte, le filtre de Kalman est optimal au sens de l'erreur quadratique moyenne, même si les observations suivent une loi Student- t .

À l'inverse, le modèle DCS repose sur une dynamique score-driven de la forme, qui ne correspond pas exactement au processus de génération de l'état latent. Cette différence de spécification limite la capacité du modèle DCS à reproduire fidèlement la dynamique réelle.

L'effet de la taille du panel N est également très marqué. Lorsque N augmente, la MSE diminue fortement pour les deux modèles, mais beaucoup plus rapidement pour le filtre de Kalman. Cette amélioration s'explique par le fait que l'information contenue dans les observations devient plus riche, ce qui permet une estimation plus précise de l'état latent.

Concernant l'effet du paramètre ν , on observe que la MSE diminue pour les deux modèles lorsque ν augmente. Cela s'explique par le fait que la distribution Student- t se rapproche progressivement d'une distribution gaussienne, ce qui réduit la fréquence et l'impact des valeurs extrêmes.

Enfin, l'analyse de la décomposition biais-variance montre que le biais est faible pour les deux méthodes dans l'ensemble des configurations. La MSE est donc principalement dominée par la variance. Le filtre de Kalman présente une variance nettement plus faible que le modèle DCS, ce qui explique l'écart de performance observé entre les deux approches.

2.4 Comparaison entre le filtre de Kalman et le modèle DCS- t : paramètres estimés

Dans cette section, on se place dans un cadre plus réaliste où les paramètres du modèle ne sont plus supposés connus. Ils doivent désormais être estimés à partir

des données, ce qui permet d'évaluer l'impact de l'incertitude d'estimation sur les performances des deux approches.

Le cadre reste identique à celui de la partie précédente : l'état latent β_t suit une marche aléatoire gaussienne, tandis que les observations sont générées avec des erreurs suivant une loi de Student- t .

2.4.1 Estimation des paramètres

Filtre de Kalman

Quant au filtre de Kalman gaussien, on calcule par maximum de vraisemblance la valeur des paramètres $(\sigma_\xi^2, \sigma_v^2)$, sous l'hypothèse que les erreurs de mesure sont gaussiennes :

$$v_t \sim \mathcal{N}(0, \sigma_v^2 I_N).$$

Filtre DCS- t

Pour le modèle DCS- t , on considère le vecteur de paramètres

$$\theta = (\sigma_v^2, \kappa, \nu)'$$

Ces paramètres sont estimés par maximum de vraisemblance à partir de la densité conditionnelle de distribution t de Student. L'évolution du processus latent est contrôlée par le gradient de la log-vraisemblance conditionnelle :

$$u_t = \frac{\partial \log f_t(\mathbf{z}_t; \theta)}{\partial \beta_t},$$

où $f_t(\cdot)$ représente la distribution multidimensionnelle.

La densité s'écrit :

$$f_t(\mathbf{z}_t; \theta) = \frac{\Gamma\left(\frac{\nu+N}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) (\nu\pi)^{N/2} |\sigma_v^2 I_N|^{1/2}} \left(1 + \frac{1}{\nu} \mathbf{e}_t' (\sigma_v^2 I_N)^{-1} \mathbf{e}_t\right)^{-\frac{\nu+N}{2}} \quad (2.5)$$

$$= \frac{\Gamma\left(\frac{\nu+N}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) (\nu\pi\sigma_v^2)^{N/2}} \left(1 + \frac{\mathbf{e}_t' \mathbf{e}_t}{\nu\sigma_v^2}\right)^{-\frac{\nu+N}{2}}, \quad (2.6)$$

avec N la dimension de $\mathbf{z}_t$.

La log-densité associée est donnée par :

$$\log f_t(\mathbf{z}_t; \theta) = \log \Gamma\left(\frac{\nu + N}{2}\right) - \log \Gamma\left(\frac{\nu}{2}\right) - \frac{N}{2} \log(\nu \pi \sigma_v^2) - \frac{\nu + N}{2} \log\left(1 + \frac{\mathbf{e}_t' \mathbf{e}_t}{\nu \sigma_v^2}\right). \quad (2.7)$$

La log-vraisemblance conditionnelle du modèle s'écrit alors :

$$\mathcal{L}(\theta) = \sum_{t=1}^T \log f_t(\mathbf{z}_t; \theta), \quad (2.8)$$

où la trajectoire $\{\beta_t\}$ est générée par la dynamique score-driven du modèle.

L'estimation consiste à résoudre :

$$\hat{\theta} = \arg \max_{\theta} \mathcal{L}(\theta),$$

cette optimisation est réalisée numériquement à l'aide de l'algorithme L-BFGS-B .

2.4.2 Objectif

Dans cette partie, le but est de comparer les performances des deux méthodes dans un cadre plus proche de la réalité. Les paramètres ne sont plus connus et il faut les estimer à partir des données. On veut savoir comment cette étape d'estimation influence la qualité de l'estimation de l'état latent. On remarque aussi la différence entre le filtre de Kalman et le modèle DCS-t.

2.4.3 Résultats et Analyse

TABLE 2.4 – Performances de KF et DCS : MSE, variance et biais.

N	ν	KF			DCS		
		MSE	Var	Bias	MSE	Var	Bias
5	3	0.148	0.141	0.081	0.134	0.129	0.072
5	5	0.098	0.095	0.057	0.125	0.121	0.064
5	10	0.082	0.079	0.050	0.118	0.115	0.059
5	20	0.077	0.075	0.045	0.115	0.112	0.056
5	50	0.075	0.072	0.047	0.114	0.111	0.058
20	3	0.061	0.060	0.037	0.083	0.081	0.041
20	5	0.042	0.041	0.028	0.078	0.077	0.036
20	10	0.034	0.033	0.025	0.074	0.072	0.037
20	20	0.031	0.031	0.022	0.071	0.070	0.033
20	50	0.030	0.029	0.023	0.070	0.069	0.035
40	3	0.038	0.037	0.026	0.073	0.072	0.035
40	5	0.026	0.026	0.019	0.067	0.066	0.032
40	10	0.021	0.020	0.016	0.062	0.062	0.028
40	20	0.019	0.019	0.016	0.059	0.059	0.028
40	50	0.018	0.018	0.014	0.058	0.057	0.025
60	3	0.029	0.029	0.021	0.070	0.069	0.035
60	5	0.019	0.018	0.016	0.062	0.061	0.030
60	10	0.015	0.015	0.013	0.058	0.058	0.026
60	20	0.014	0.014	0.012	0.055	0.054	0.024
60	50	0.013	0.013	0.012	0.053	0.053	0.024
100	3	0.021	0.020	0.015	0.066	0.065	0.031
100	5	0.012	0.012	0.011	0.059	0.058	0.026
100	10	0.010	0.010	0.010	0.054	0.053	0.024
100	20	0.009	0.009	0.009	0.050	0.050	0.021
100	50	0.009	0.008	0.009	0.051	0.051	0.023

Le Tableau 2.4 présente les résultats en termes d'erreur quadratique moyenne (MSE), de variance et de biais pour différentes valeurs de N et de ν . Plusieurs

observations importantes peuvent être mises en évidence.

La comparaison des performances entre les deux méthodes montre que le filtre de Kalman obtient globalement une MSE plus faible que le modèle DCS dans la majorité des configurations. Cet écart est particulièrement marqué lorsque la taille du panel N augmente. Seul le cas $N = 5$ et $\nu = 3$ montre un léger avantage du modèle DCS, mais cette situation reste limitée.

Une première explication vient du fait que, dans cette simulation, la dynamique utilisée pour générer l'état latent correspond précisément à celle supposée par le filtre de Kalman. Le modèle est donc correctement spécifié dans le cadre gaussien, ce qui favorise naturellement les performances du filtre. À l'inverse, le modèle DCS repose sur une dynamique score-driven différente du mécanisme de génération des données, ce qui introduit une certaine forme de mauvaise spécification dynamique.

On observe que la MSE diminue dans les deux modèles quand la taille du panel N augmente, même si la baisse est plus marquée pour le filtre de Kalman. L'effet d'agrégation qui résulte de la présence d'un plus grand nombre d'observations à chaque date fait que les erreurs individuelles se compensent partiellement entre elles. Ainsi, même si les observations suivent des lois à queues épaisses, le bruit global tend progressivement vers un comportement gaussien. Le filtre de Kalman exploite très bien l'information disponible dans ce cas, et fournit donc des estimations plus précises.

Dans le modèle DCS, la mise à jour de l'état dépend du score (2.3). Le terme $\mathbf{1}'_N \mathbf{e}_t$ représente la somme des erreurs individuelles, ce qui signifie que le modèle utilise lui aussi l'ensemble des observations disponibles à chaque date. Lorsque N augmente, cette agrégation apporte davantage d'information et permet de réduire la variabilité relative du bruit, améliorant ainsi la précision des estimations. Cet effet reste toutefois partiellement atténué par le terme de normalisation ω_t (2.4). En effet, lorsque le nombre d'observations augmente, la quantité $\mathbf{e}'_t \mathbf{e}_t$ devient plus importante, ce qui accroît ω_t et réduit l'impact du score u_t dans la mise à jour de l'état latent. Le modèle DCS profite donc lui aussi de l'augmentation de N , mais dans une moindre mesure que le filtre de Kalman.

On remarque aussi que la MSE diminue dans les deux modèles lorsque ν augmente. Cela vient du fait que la distribution Student- t se rapproche progressivement d'une loi gaussienne, ce qui réduit à la fois la fréquence et l'impact des observations

extrêmes. La variance d'une loi Student- t est donnée par :

$$\sigma_v^2 \frac{\nu}{\nu - 2}, \quad (\nu > 2),$$

de sorte que, lorsque ν devient plus grand, la variance effective se rapproche progressivement de σ_v^2 . Cette amélioration reste cependant beaucoup plus marquée pour le filtre de Kalman que pour le modèle DCS. La raison tient principalement au mécanisme d'adaptation utilisé par les deux approches. Dans le filtre de Kalman, le gain K_t dépend directement de la variance des erreurs (1.5). Ainsi, lorsque la variance des observations diminue, le gain s'ajuste automatiquement et exploite plus efficacement l'information contenue dans les données. Cela réduit fortement la variance de l'estimation et, par conséquent, la MSE.

Le modèle DCS repose sur une logique de mise à jour différente, donnée par (2.2)

$$\beta_{t+1} = \beta_t + \kappa u_t,$$

où le paramètre κ reste constant dans le temps. Lorsque ν augmente, le terme de pondération ω_t tend progressivement vers 1. La mise à jour devient alors proche d'un mécanisme linéaire avec un gain fixe, ce qui fait que le modèle tire moins parti de l'amélioration de la qualité des observations. La diminution de la MSE reste donc plus limitée. À l'inverse, lorsque ν prend de faibles valeurs, les données comportent davantage d'observations extrêmes. Dans ce contexte, le modèle DCS peut légèrement mieux se comporter lorsque le nombre d'observations est réduit ($N = 5$), notamment pour $\nu = 3$ ou $\nu = 5$. Cela vient de sa capacité à atténuer l'influence des valeurs atypiques. Cet avantage devient cependant moins visible lorsque ν augmente ou lorsque la taille du panel N devient plus importante.

TABLE 2.5 – Estimation des paramètres pour KF et DCS.

N	ν	KF		DCS		
		$\hat{\sigma}_\xi^2$	$\hat{\sigma}_v^2$	$\hat{\sigma}_v^2$	$\hat{\nu}$	κ
5	3	0.058	2.880	1.187	3.56	0.092
5	5	0.041	1.660	1.149	6.01	0.090
5	10	0.040	1.249	1.135	13.22	0.087
5	20	0.041	1.108	1.121	35.22	0.083
5	50	0.040	1.044	1.109	90.84	0.081
20	3	0.043	3.012	1.139	3.50	0.032
20	5	0.041	1.675	1.108	5.88	0.033
20	10	0.040	1.246	1.086	12.00	0.033
20	20	0.040	1.111	1.078	24.58	0.033
20	50	0.040	1.042	1.070	65.41	0.032
40	3	0.044	3.043	1.126	3.56	0.018
40	5	0.040	1.671	1.100	5.89	0.019
40	10	0.041	1.246	1.075	11.92	0.019
40	20	0.040	1.111	1.065	23.66	0.019
40	50	0.040	1.041	1.057	58.73	0.019
60	3	0.042	2.894	1.128	3.58	0.012
60	5	0.040	1.666	1.097	5.97	0.013
60	10	0.040	1.248	1.072	12.00	0.014
60	20	0.040	1.108	1.059	23.84	0.014
60	50	0.040	1.042	1.054	57.68	0.014
100	3	0.042	2.924	1.123	3.56	0.008
100	5	0.040	1.658	1.091	5.98	0.008
100	10	0.040	1.249	1.069	11.99	0.009
100	20	0.040	1.113	1.058	23.53	0.009
100	50	0.039	1.042	1.047	57.62	0.009

Le Tableau 2.5 présente les estimations des paramètres pour le filtre de Kalman et le modèle DCS pour différentes valeurs de N et de ν . Plusieurs résultats importants peuvent être mis en évidence.

Tout d’abord, concernant le filtre de Kalman, on observe que l’estimation de la

variance du bruit d'état $\hat{\sigma}_\xi^2$ est globalement proche de la valeur vraie (égale à 0.04) dans la majorité des configurations. Cela confirme que le modèle est correctement spécifié au niveau de la dynamique de l'état latent.

L'interprétation de l'estimation de la variance des observations $\hat{\sigma}_v^2$ diffère selon les deux modèles.

Dans le filtre de Kalman, les observations sont supposées gaussiennes avec une variance σ_v^2 . Toutefois, dans notre cadre de simulation, les données sont générées selon une loi Student-t de paramètre de scale σ_v^2 . Or, la variance réelle d'une loi Student-t est donnée par :

$$\text{Var}(v_t) = \sigma_v^2 \cdot \frac{\nu}{\nu - 2}, \quad \text{pour } \nu > 2.$$

Ainsi, le paramètre σ_v^2 dans la génération ne correspond pas directement à la variance des observations. Les résultats montrent que $\hat{\sigma}_v^2$ est très proche de $\sigma_v^2 \cdot \frac{\nu}{\nu-2}$, ce qui indique que le modèle capture correctement le niveau de dispersion des observations, même en présence de queues épaisses.

Du côté du modèle DCS, on observe que l'estimation de $\hat{\sigma}_v^2$ reste proche du paramètre de scale σ_v^2 pour toutes les configurations. Ce résultat s'explique par la structure du modèle DCS, qui est directement basé sur la densité Student-t et qui distingue explicitement le paramètre de scale de la variance.

L'estimation du paramètre ν dans le modèle DCS est également cohérente. Pour des valeurs faibles de ν , l'estimation est proche de la valeur vraie. Lorsque ν augmente, on observe que $\hat{\nu}$ devient plus élevé et plus variable. Cela s'explique par le fait que, lorsque la distribution se rapproche d'une loi gaussienne, le paramètre ν devient plus difficile à identifier précisément.

Enfin, le paramètre κ diminue fortement lorsque N augmente. Ce résultat est cohérent avec la structure du modèle DCS. En effet, κ contrôle l'intensité de la mise à jour de l'état latent. Lorsque le nombre d'observations augmente, le score agrège davantage d'information à chaque période, ce qui rend la mise à jour potentiellement plus instable si κ reste élevé. L'estimation ajuste donc κ à la baisse afin de maintenir une dynamique stable.

2.5 Scénario 1 : Cadre gaussien correctement spécifié

Dans ce premier scénario, nous considérons un cadre entièrement gaussien, dans lequel le modèle d'état et le modèle d'observation sont correctement spécifiés.

La variable latente suit une marche aléatoire classique. Pour les observations, les erreurs d'observation v_t sont supposées gaussiennes, donc $v_t \sim \mathcal{N}(0, \sigma_v^2 I_N)$.

Hypothèse de paramètres connus

Dans ce scénario, les paramètres sont supposés connus. Le filtre de Kalman utilise directement les valeurs vraies de σ_ξ^2 et σ_v^2 , tandis que le modèle DCS utilise les valeurs vraies de σ_v^2 et ν . Le paramètre κ est calibré pour assurer la cohérence avec la variance de l'état latent.

2.5.1 Résultats et Analyse

N	ν	KF			DCS		
		MSE	Var	Bias	MSE	Var	Bias
5	3	0.0712	0.0712	0.0022	0.1235	0.1235	0.0025
5	5	0.0725	0.0725	-0.0015	0.1199	0.1199	-0.0033
5	10	0.0712	0.0712	-0.0046	0.1150	0.1150	-0.0052
5	20	0.0720	0.0720	0.0017	0.1130	0.1130	0.0030
5	50	0.0719	0.0719	-0.0005	0.1122	0.1122	0.0001
20	3	0.0291	0.0291	0.0005	0.0746	0.0746	0.0010
20	5	0.0289	0.0289	0.0015	0.0721	0.0721	0.0018
20	10	0.0289	0.0289	-0.0015	0.0721	0.0720	-0.0029
20	20	0.0288	0.0288	0.0008	0.0705	0.0705	0.0006
20	50	0.0289	0.0289	-0.0010	0.0694	0.0694	-0.0017
40	3	0.0174	0.0174	0.0002	0.0597	0.0597	-0.0001
40	5	0.0174	0.0174	-0.0001	0.0599	0.0599	0.0004
40	10	0.0174	0.0174	0.0004	0.0596	0.0596	0.0014
40	20	0.0176	0.0176	0.0003	0.0589	0.0589	0.0006
40	50	0.0175	0.0175	0.0000	0.0580	0.0580	-0.0002
60	3	0.0127	0.0127	-0.0009	0.0546	0.0546	-0.0030
60	5	0.0127	0.0127	-0.0002	0.0540	0.0540	-0.0008
60	10	0.0127	0.0127	-0.0006	0.0538	0.0538	-0.0007
60	20	0.0128	0.0128	-0.0001	0.0545	0.0545	-0.0001
60	50	0.0126	0.0126	-0.0002	0.0531	0.0531	0.0001
100	3	0.0083	0.0083	0.0001	0.0492	0.0492	0.0005
100	5	0.0083	0.0083	-0.0000	0.0496	0.0496	-0.0003
100	10	0.0083	0.0083	0.0002	0.0494	0.0494	-0.0006
100	20	0.0083	0.0083	0.0002	0.0489	0.0489	0.0001
100	50	0.0083	0.0083	-0.0004	0.0486	0.0486	-0.0009

TABLE 2.6 – Comparaison des performances de KF et DCS pour différentes valeurs de N et ν .

Les résultats montrent que le filtre de Kalman a une erreur quadratique moyenne plus basse que le modèle DCS dans toutes les configurations. Ce résultat s'explique par le cadre de simulation utilisé. Comme les données ont été générées selon une loi normale, elles respectent bien les hypothèses sur lesquelles repose le filtre de Kalman. Dans ce cas, il est normal que le MSE soit le plus bas.

Quand on observe la décomposition biais-variance, on voit que le biais reste très faible pour les deux méthodes. Les estimations correspondent bien à la valeur réelle. Les différences observées sur la MSE viennent surtout de la variance. À ce niveau, le filtre de Kalman montre une variabilité plus faible. Cet avantage donne au filtre de Kalman de meilleurs résultats dans l'ensemble.

Quand on augmente le paramètre ν , le modèle DCS donne de meilleurs résultats. La distribution Student- t finit par ressembler à la loi normale. Les observations deviennent alors moins exposées aux valeurs extrêmes. Le modèle DCS devient alors plus proche du mécanisme de génération des données. Néanmoins, même dans ce cas, ses performances restent en retrait par rapport au filtre de Kalman.

Au final, dans ce cadre gaussien, le filtre de Kalman apparaît comme la méthode la plus adaptée.

2.6 Scénario 2 : Estimation gaussienne sous non-gaussianité des erreurs

Dans ce second scénario, la dynamique de l'état latent reste identique à celle du premier cadre et est donnée par :

$$\beta_t = \beta_{t-1} + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \sigma_\xi^2). \quad (2.9)$$

Les observations sont générées selon un modèle :

$$\mathbf{z}_t = \beta_t \mathbf{1}_N + v_t. \quad (2.10)$$

Les erreurs suivent une loi de Student- t :

$$v_{it} \sim t_\nu(0, \sigma_v^2), \quad i = 1, \dots, N. \quad (2.11)$$

Ce cadre apporte une nouvelle source de non-gaussianité dans les données. Les

données montrent alors plus souvent des observations extrêmes que dans une situation normale. Quand ν est petit, la distribution a des queues épaisses. Les observations varient alors beaucoup plus.

Estimation sous mauvaise spécification

Malgré cette structure non gaussienne, le filtre de Kalman est estimé en supposant à tort que les erreurs sont gaussiennes :

$$v_t \sim \mathcal{N}(0, \sigma_v^2 I_N).$$

Les paramètres $(\sigma_\xi^2, \sigma_v^2)$ sont alors obtenus par maximisation de la vraisemblance gaussienne. Cette situation correspond à un cas de mauvaise spécification du modèle, dans lequel la loi utilisée pour l'estimation diffère de la loi réelle des données.

Modèle DCS

Dans ce scénario, bien que les données soient générées selon une loi de Student- t , le modèle DCS est également estimé sous une hypothèse gaussienne. Seuls les paramètres σ_v^2 et κ sont estimés par maximum de vraisemblance gaussienne, le paramètre ν est considéré comme connu et n'est pas réestimé.

Cependant, la mise à jour dynamique conserve un mécanisme de pondération, le score u_t , inspiré du score Student- t , bien que l'estimation des paramètres repose sur hypothèse gaussienne.

Objectif

Ce scénario sert à comparer deux méthodes quand les données ne suivent pas la loi normale. La première méthode suppose à tort que les valeurs sont normales avec le filtre de Kalman. La seconde méthode prend un modèle DCS qui ne convient pas bien à la situation non plus.

Le but est de voir comment une mauvaise spécification change les performances pour estimer l'état latent. Il faut aussi mesurer jusqu'où négliger les queues épaisses détériore les résultats.

2.6.1 Résultats et Analyse

TABLE 2.7 – Performances de KF et DCS-Gauss : MSE, variance et biais.

N	ν	KF			DCS-Gauss		
		MSE	Var	Bias	MSE	Var	Bias
5	3	0.140	0.133	0.079	0.667	0.368	0.547
5	5	0.099	0.096	0.057	0.695	0.342	0.594
5	10	0.086	0.084	0.047	1.136	0.477	0.812
5	20	0.076	0.073	0.050	0.671	0.360	0.557
5	50	0.075	0.072	0.047	0.687	0.354	0.577
20	3	0.060	0.058	0.036	0.199	0.162	0.192
20	5	0.042	0.041	0.027	0.171	0.142	0.168
20	10	0.034	0.034	0.023	0.173	0.142	0.177
20	20	0.032	0.031	0.023	0.185	0.149	0.191
20	50	0.030	0.030	0.023	0.216	0.150	0.257
40	3	0.040	0.039	0.029	0.087	0.084	0.055
40	5	0.026	0.025	0.019	0.084	0.081	0.052
40	10	0.021	0.020	0.016	0.085	0.081	0.061
40	20	0.019	0.019	0.015	0.088	0.082	0.075
40	50	0.018	0.018	0.015	0.092	0.085	0.084
60	3	0.028	0.028	0.021	0.073	0.071	0.041
60	5	0.019	0.019	0.013	0.067	0.066	0.034
60	10	0.015	0.015	0.012	0.064	0.063	0.037
60	20	0.014	0.014	0.014	0.063	0.061	0.042
60	50	0.013	0.013	0.012	0.066	0.063	0.053
100	3	0.020	0.020	0.014	0.064	0.063	0.030
100	5	0.012	0.012	0.011	0.058	0.057	0.026
100	10	0.010	0.010	0.009	0.054	0.053	0.023
100	20	0.009	0.009	0.009	0.051	0.050	0.026
100	50	0.009	0.009	0.008	0.051	0.050	0.027

Les résultats montrent que le filtre de Kalman demeure systématiquement plus performant que le modèle DCS en termes d'erreur quadratique moyenne (MSE),

pour l'ensemble des configurations considérées.

On peut expliquer cette observation surtout par la mauvaise définition du modèle DCS utilisé. Les données suivent une loi de Student- t , mais le modèle DCS utilise ici une hypothèse gaussienne pour l'estimation. Le paramètre ν qui gère l'épaisseur des queues de la distribution ne se trouve pas directement dans la densité utilisée pour l'estimation.

Le terme ω_t^{-1} joue un rôle de pondération essentiel en réduisant l'influence des observations extrêmes. Toutefois, comme les paramètres sont estimés sous une hypothèse gaussienne, ce mécanisme de robustesse n'est pas pleinement cohérent avec la vraisemblance utilisée.

En particulier, pour des valeurs faibles de ν , la distribution présente des queues épaisses, ce qui entraîne la présence fréquente d'observations extrêmes. Dans ce contexte, l'estimation gaussienne des paramètres ne permet pas de capturer correctement cette hétérogénéité, ce qui peut conduire à une instabilité dans la mise à jour de l'état latent β_t et à une augmentation du biais et de la variance.

L'analyse de la décomposition biais-variance confirme ce phénomène : le modèle DCS présente un biais significativement plus élevé que le filtre de Kalman, en particulier pour les petites tailles de panel. Ainsi, la MSE du DCS est largement dominée par le biais, lorsque la taille du panel N augmente, le biais diminue rapidement et devient négligeable par rapport à la variance. Dans ce cas, la MSE est principalement dominée par la variance. La valeur du filtre de Kalman dépend surtout de la variance. L'augmentation de la taille du panel N améliore les performances des deux méthodes, en réduisant l'impact du bruit d'observation.

TABLE 2.8 – Estimation des paramètres pour KF et DCS.

N	ν	KF		DCS	
		$\hat{\sigma}_\xi^2$	$\hat{\sigma}_v^2$	$\hat{\sigma}_v^2$	κ
5	3	0.051	2.886	3.484	0.097
5	5	0.042	1.673	2.341	0.064
5	10	0.042	1.255	2.229	0.047
5	20	0.040	1.104	1.801	0.052
5	50	0.040	1.046	1.772	0.044
20	3	0.041	2.993	3.690	0.026
20	5	0.041	1.654	2.475	0.022
20	10	0.041	1.243	2.042	0.023
20	20	0.041	1.112	1.841	0.023
20	50	0.041	1.040	1.843	0.020
40	3	0.041	3.162	3.815	0.016
40	5	0.041	1.659	2.280	0.015
40	10	0.041	1.252	1.981	0.015
40	20	0.040	1.114	1.952	0.015
40	50	0.040	1.043	1.794	0.015
60	3	0.041	2.949	3.731	0.012
60	5	0.041	1.672	2.372	0.012
60	10	0.041	1.253	1.940	0.012
60	20	0.039	1.111	1.738	0.012
60	50	0.040	1.039	1.724	0.012
100	3	0.041	2.944	3.230	0.008
100	5	0.040	1.669	1.892	0.009
100	10	0.040	1.256	1.808	0.009
100	20	0.039	1.113	1.769	0.009
100	50	0.040	1.040	1.651	0.009

Le paramètre σ_v^2 de la suite de modèle DCS reste élevé en comparaison de la valeur réelle, en particulier lorsque ν est petit. Cela se doit aux valeurs extrêmes de la distribution de Student- t . Puisque le modèle DCS n'intègre pas ces valeurs extrêmes de manière pondérée, elles sont comprises dans la variance et le paramètre

σ_v^2 en est surestimé.

On voit que le paramètre κ baisse quand la taille du panel N grandit. Ce résultat suit la structure du score, car la somme des résidus $\mathbf{1}'_N \mathbf{e}_t$ augmente avec N . Pour garder une dynamique stable de l'état latent, le paramètre κ baisse et permet une forme de normalisation.

Quand la valeur de ν monte, les estimations de σ_v^2 baissent. Les estimations de σ_v^2 se rapprochent de la vraie valeur. La distribution de Student-t finit par devenir proche de la loi normale, ce qui diminue le nombre d'observations extrêmes ainsi que leur effet.

Les résultats indiquent que le modèle DCS avec une hypothèse gaussienne n'est pas capable de représenter la structure à queues épaisses. Le modèle DCS donne alors de mauvaises estimations des paramètres. Il est alors moins efficace.

2.7 Scénario 3 : Modélisation d'un régime de crise

Dans ce scénario, nous reproduisons une situation économique réaliste dans laquelle le marché entre temporairement dans un régime de forte volatilité. Ce type de comportement est fréquemment observé lors de périodes de crise financière, caractérisées par la présence d'observations extrêmes et une augmentation soudaine de la variance.

Régime de crise

On introduit une variable d'état binaire : $C_t \in 0, 1$, définie par :

$$C_t = \begin{cases} 0 & \text{régime normal,} \\ 1 & \text{régime de crise.} \end{cases}$$

À chaque période t , une variable aléatoire $u_t \sim \mathcal{U}(0, 1)$ est générée. Une phase de crise débute lorsque $u_t < p$, où $p = 0.02$ dans ce scénario.

Une fois déclenchée, la crise persiste pendant L périodes consécutives :

$$C_t = 1 \quad \text{pour } t, t+1, \dots, t+L.$$

Après cette phase, le système revient à un régime normal ($C_t = 0$). Il est donc pos-

sible d'observer plusieurs épisodes de crise au sein d'un même échantillon, séparés par des périodes plus calmes.

Équation d'observation

Pour chaque individu $i = 1, \dots, N$, les observations s'écrivent sous la forme :

$$z_{i,t} = \beta_t + v_{i,t},$$

où les erreurs suivent une loi de Student- t dont la variance dépend du régime considéré :

$$v_{i,t} \sim t_\nu(0, \sigma_t^2),$$

avec

$$\sigma_t^2 = \begin{cases} \sigma_v^2 & \text{si } C_t = 0, \\ m^2 \sigma_v^2 & \text{si } C_t = 1. \end{cases}$$

Effet des paramètres de crise

Le paramètre $m > 1$ joue sur l'intensité des chocs : plus il est grand, plus les observations extrêmes sont marquées. Le paramètre L , quant à lui, contrôle la durée des épisodes de crise. Lorsque L augmente, ces périodes de forte volatilité ont tendance à durer plus longtemps.

Ainsi, m influence l'intensité des chocs, tandis que L contrôle leur persistance, deux dimensions essentielles pour caractériser les épisodes de crise.

Objectif

Dans ce cas, il faut voir si les méthodes d'estimation gardent leur fiabilité quand il y a de la forte volatilité et des valeurs extrêmes.

2.7.1 Résultats et Analyse

TABLE 2.9 – Comparaison des performances KF vs DCS avec $m = 20$, $L = 6$.

N	ν	KF			DCS		
		MSE	Var	Bias	MSE	Var	Bias
5	3	3.157	2.916	0.042	0.254	0.224	0.027
5	5	1.191	1.029	0.008	0.227	0.202	-0.003
5	10	1.108	0.969	0.052	0.222	0.193	0.008
5	20	0.927	0.814	0.017	0.196	0.181	-0.006
5	50	0.817	0.693	-0.022	0.198	0.180	-0.004
20	3	0.726	0.666	-0.028	0.105	0.103	-0.001
20	5	0.589	0.540	-0.002	0.100	0.097	0.000
20	10	0.405	0.372	0.035	0.094	0.092	0.006
20	20	0.328	0.300	0.001	0.094	0.091	-0.003
20	50	0.307	0.278	-0.009	0.093	0.090	0.000
40	3	0.447	0.405	0.023	0.092	0.090	0.007
40	5	0.289	0.267	-0.006	0.087	0.085	-0.004
40	10	0.234	0.221	-0.006	0.081	0.079	-0.001
40	20	0.230	0.214	-0.007	0.077	0.075	-0.002
40	50	0.215	0.203	0.001	0.075	0.074	-0.002
60	3	0.358	0.336	0.009	0.089	0.087	-0.002
60	5	0.250	0.234	-0.010	0.084	0.082	0.000
60	10	0.188	0.177	0.002	0.079	0.078	0.000
60	20	0.181	0.170	-0.003	0.077	0.075	-0.001
60	50	0.184	0.174	0.012	0.070	0.069	0.008
100	3	0.250	0.235	-0.009	0.086	0.084	-0.004
100	5	0.224	0.214	-0.001	0.081	0.079	0.001
100	10	0.129	0.123	0.008	0.068	0.067	0.002
100	20	0.129	0.124	-0.002	0.068	0.066	0.001
100	50	0.123	0.118	-0.006	0.075	0.073	-0.003

Au Tableau 2.9, on présente les performances du filtre de Kalman et du modèle DCS dans un scénario de crise avec des phases temporaires de très grande volatilité,

avec $m = 20$ et $L = 6$.

On note que, quel que soit le cas, le modèle DCS surpasse largement le filtre de Kalman.

Quand il y a crise, la variance des erreurs d'observation augmente beaucoup. On voit alors des valeurs extrêmes. Dans ce problème, le filtre de Kalman, basé sur une variance stable et sur l'hypothèse que tout suit une loi normale, réagit trop fortement face à cette innovation. C'est-à-dire que la variance des estimations augmente beaucoup. À l'inverse, le modèle DCS basé sur la distribution de Student- t introduit un mécanisme de pondération adaptative à travers le terme ω , qui réduit automatiquement l'influence des observations extrêmes. En effet, lorsque les résidus deviennent importants, le facteur ω_t augmente, ce qui diminue l'impact du score sur la mise à jour de l'état latent.

TABLE 2.10 – Estimation des paramètres pour KF et DCS.

N	ν	KF		DCS		
		$\hat{\sigma}_\xi^2$	$\hat{\sigma}_v^2$	$\hat{\sigma}_v^2$	$\hat{\nu}$	κ
5	3	1.895	121.821	1.245	2.26	0.040
5	5	0.385	72.562	1.142	2.32	0.040
5	10	0.358	56.435	1.067	2.55	0.040
5	20	0.174	46.442	1.014	2.91	0.040
5	50	0.121	45.498	0.992	2.78	0.040
20	3	0.241	125.513	1.298	2.23	0.033
20	5	0.191	80.078	1.230	2.31	0.033
20	10	0.111	56.422	1.184	2.52	0.033
20	20	0.055	51.961	1.160	2.66	0.034
20	50	0.054	47.348	1.143	3.22	0.033
40	3	0.144	132.472	1.287	2.24	0.019
40	5	0.065	75.292	1.236	2.38	0.019
40	10	0.054	54.345	1.186	2.64	0.019
40	20	0.053	48.847	1.167	2.94	0.020
40	50	0.054	44.460	1.155	3.19	0.020
60	3	0.180	127.727	1.288	2.25	0.013
60	5	0.061	78.017	1.243	2.31	0.013
60	10	0.053	54.063	1.195	2.60	0.014
60	20	0.057	49.009	1.181	2.65	0.014
60	50	0.054	47.007	1.169	3.45	0.014
100	3	0.100	121.443	1.283	2.24	0.008
100	5	0.114	75.840	1.250	2.38	0.009
100	10	0.043	56.367	1.193	2.67	0.009
100	20	0.051	46.700	1.171	3.19	0.009
100	50	0.044	47.551	1.178	3.90	0.009

À travers le Tableau 2.10 sont résumées les estimations des paramètres des deux modèles en temps de crise.

On observe assez rapidement que le comportement des deux modèles diffère fortement dans ce type de situation. Les écarts sont nettement plus marqués que

dans les scénarios précédents.

Du côté du filtre de Kalman, les estimations de σ_v^2 et σ_ξ^2 apparaissent nettement trop élevées dans ce scénario. On observe notamment que la variance d'observation peut atteindre des niveaux bien supérieurs à la valeur fixée lors de la simulation.

Ce comportement s'explique assez naturellement. Le modèle suppose des erreurs gaussiennes, ce qui devient problématique en période de crise, où la variabilité augmente fortement et où des observations extrêmes apparaissent plus fréquemment. Dans ce contexte, le filtre réagit en “gonflant” la variance afin de tenir compte de ces écarts importants. Ce mécanisme lui permet de continuer à s'ajuster aux données, mais au prix d'une dégradation de l'estimation de l'état latent, qui devient plus instable.

Pour le modèle DCS fonctionne ici différemment et, dans ce contexte de crise, il s'adapte globalement mieux. On voit que les estimations de σ_v^2 restent proches de la vraie valeur. Il n'y a pas de dérive notable. Le modèle tient mieux compte de la variabilité des observations, même si les observations deviennent plus instables.

La valeur de ν reste assez faible selon l'estimation. Ce résultat est cohérent avec la présence de queues épaisses dans les données. Concrètement, cela permet de limiter l'influence des observations les plus extrêmes lors de la mise à jour de l'état. Les estimations restent stables et changent peu même quand il y a un événement imprévu.

Ce comportement montre que le modèle DCS est capable de s'adapter automatiquement aux phases de crise en ajustant la forme de la distribution des erreurs, sans avoir besoin de gonfler artificiellement la variance. Enfin, le paramètre κ diminue lorsque la taille du panel N augmente.

TABLE 2.11 – Performances de KF et DCS en fonction de la période de crise L , avec $N = 40$, $\nu = 5$, $p = 0.02$ et $m = 20$.

L	KF			DCS		
	MSE	Var	Bias	MSE	Var	Bias
1	0.145	0.145	0.004	0.069	0.069	0.002
2	0.195	0.195	0.001	0.070	0.070	0.000
4	0.252	0.252	-0.004	0.078	0.078	0.001
6	0.325	0.325	-0.009	0.087	0.087	-0.001
10	0.372	0.372	0.008	0.114	0.114	0.001
15	0.454	0.453	-0.016	0.147	0.147	0.000
20	0.448	0.448	0.003	0.202	0.202	0.001
25	0.490	0.489	0.010	0.255	0.254	0.020
30	0.525	0.525	-0.015	0.295	0.295	0.002
40	0.571	0.571	0.004	0.444	0.444	0.009

Selon le Tableau 2.11, la MSE semble augmenter pour les deux méthodes quand la durée de la crise L s'allonge. Cela s'explique probablement par le fait que les crises plus longues génèrent davantage d'observations extrêmes, ce qui finit par compliquer l'estimation de l'état latent.

Cependant, cette dégradation est nettement plus marquée pour le filtre de Kalman. Lorsque les crises deviennent plus longues, les erreurs d'estimation s'accumulent dans le temps, ce qui entraîne une augmentation importante de la variance et, par conséquent, de la MSE.

Le modèle DCS garde plus de stabilité quand la crise dure longtemps. La structure du modèle avec la distribution de Student- t permet de mettre en place une pondération qui limite l'impact des valeurs extrêmes. Ainsi, même si la MSE augmente avec L , cette augmentation est plus progressive que pour le filtre de Kalman.

On voit que le biais est très faible pour les deux méthodes. La MSE vient donc surtout de la variance. Le problème principal dans cette situation vient de l'instabilité créée quand la volatilité devient forte.

TABLE 2.12 – Performances de KF et DCS en fonction de l'intensité de la crise m , avec $N = 40$, $\nu = 5$, $p = 0.02$ et $L = 10$.

m	KF			DCS		
	MSE	Var	Bias	MSE	Var	Bias
5	0.078	0.078	0.002	0.099	0.099	0.002
10	0.185	0.185	-0.006	0.105	0.105	0.000
20	0.370	0.370	-0.008	0.111	0.111	0.000
30	0.615	0.615	0.001	0.112	0.112	0.002
40	0.887	0.887	0.017	0.115	0.115	0.001
50	1.272	1.271	-0.028	0.110	0.110	0.000

Les résultats montrent que l'intensité de la crise, mesurée par le paramètre m , a un impact très différent sur les performances des deux méthodes.

À mesure que m augmente, l'erreur quadratique moyenne du filtre de Kalman s'accroît de façon marquée. En effet, la variance des erreurs d'observation devient proportionnelle à m^2 , ce qui produit des innovations de plus grande amplitude.

La MSE du modèle DCS reste remarquablement stable lorsque m augmente lorsque les résidus deviennent très importants, le terme de normalisation ω_t croît rapidement, ce qui réduit automatiquement l'impact des observations extrêmes sur la mise à jour de l'état latent.

Quand les crises deviennent très fortes, le modèle DCS continue de donner une estimation stable. Le filtre de Kalman perd beaucoup en performance dans ce cas.

2.8 Scénario 4 : Modélisation dynamique de l'état latent par un modèle DCS- t

Dans ce scénario, on ne considère plus une dynamique de marche aléatoire pour β_t . L'évolution de la variable latente est plutôt décrite à l'aide d'un modèle *score-driven* (DCS) basé sur une distribution de Student- t . L'intérêt de ce cadre est qu'il introduit un lien direct entre l'état latent et les observations passées, à travers le score de la densité conditionnelle.

Dynamique de l'état latent

L'évolution de β_t est décrite par une équation de type DCS [2.2](#) :

$$\beta_t = \beta_{t-1} + \kappa u_{t-1},$$

où u_{t-1} représente le score agrégé construit à partir de l'ensemble des observations disponibles à la date $t - 1$.

Objectif

L'objectif de ce scénario est d'évaluer les performances comparées du filtre de Kalman et du modèle DCS dans un contexte où la dynamique réelle de l'état latent est de type score-driven.

Dans ce cadre, le modèle DCS est bien spécifié puisqu'il correspond au processus de génération des données, tandis que le filtre de Kalman reste mal spécifié, la théorie étant basée sur une hypothèse de marche aléatoire et sur la loi normale des erreurs.

Ce scénario permet ainsi d'analyser l'impact d'une bonne spécification du modèle sur les performances d'estimation.

2.8.1 Résultats et Analyse

TABLE 2.13 – Performances de KF et DCS - MSE, Variance et Biais.

N	ν	KF			DCS		
		MSE	Var	Bias	MSE	Var	Bias
5	3	0.016327	0.013897	0.0493	0.001522	0.001178	0.0185
5	5	0.003746	0.002903	0.0290	0.001519	0.001222	0.0172
5	10	0.002339	0.001931	0.0202	0.001352	0.001085	0.0164
5	20	0.001761	0.001512	0.0158	0.001393	0.001155	0.0154
5	50	0.001660	0.001433	0.0151	0.001228	0.000979	0.0158
20	3	0.010271	0.009508	0.0276	0.000313	0.000294	0.0044
20	5	0.003917	0.003704	0.0146	0.000267	0.000252	0.0039
20	10	0.002482	0.002406	0.0087	0.000331	0.000315	0.0040
20	20	0.002033	0.001991	0.0065	0.000330	0.000313	0.0040
20	50	0.001829	0.001801	0.0052	0.000312	0.000297	0.0039
40	3	0.015458	0.015047	0.0202	0.000145	0.000141	0.0020
40	5	0.004586	0.004474	0.0105	0.000147	0.000143	0.0020
40	10	0.003181	0.003141	0.0062	0.000139	0.000136	0.0017
40	20	0.002769	0.002751	0.0042	0.000157	0.000153	0.0020
40	50	0.002559	0.002550	0.0030	0.000143	0.000139	0.0017
60	3	0.008705	0.008467	0.0154	0.000085	0.000084	0.0010
60	5	0.004876	0.004804	0.0084	0.000087	0.000086	0.0014
60	10	0.003674	0.003648	0.0051	0.000092	0.000090	0.0010
60	20	0.003246	0.003235	0.0033	0.000089	0.000088	0.0010
60	50	0.003026	0.003021	0.0022	0.000088	0.000087	0.0010
100	3	0.008706	0.008563	0.0120	0.000052	0.000052	0.0000
100	5	0.005161	0.005116	0.0067	0.000049	0.000049	0.0000
100	10	0.004121	0.004106	0.0039	0.000049	0.000048	0.0000
100	20	0.003669	0.003662	0.0026	0.000050	0.000049	0.0000
100	50	0.003456	0.003453	0.0017	0.000053	0.000053	0.0000

Les résultats indiquent que, dans ce scénario, le modèle DCS obtient de meilleures performances que le filtre de Kalman, et ce dans toutes les configurations étudiées.

Cet écart est particulièrement visible ici, ce qui s'explique par le fait que la dynamique de la variable latente β_t est elle-même générée à partir d'un modèle score-driven (DCS).

À l'inverse, le filtre de Kalman s'appuie sur une hypothèse de marche aléatoire qui ne correspond pas vraiment à la dynamique réelle de β_t dans ce scénario. Ce décalage se ressent directement dans les résultats : les estimations sont moins précises, avec une variabilité plus élevée et un biais qui reste non négligeable.

Le modèle DCS est ici correctement spécifié à la fois en termes de distribution des erreurs et de dynamique de l'état latent. En effet, la mise à jour de β_t repose sur le score de la vraisemblance, ce qui correspond exactement au processus générateur des données. Cela permet au modèle DCS de capturer efficacement l'évolution de l'état latent.

L'augmentation de la taille du panel améliore les performances des deux méthodes, en réduisant la variance des estimations. Toutefois, le modèle DCS conserve un avantage significatif dans toutes les configurations.

Lorsque le paramètre ν augmente, les performances du filtre de Kalman s'améliorent légèrement, en raison de la réduction des effets de queues épaisses.

La stabilité des performances du modèle DCS lorsque ν augmente peut s'expliquer par le fait que, dans ce scénario, le modèle est correctement spécifié. En effet, la dynamique de l'état latent ainsi que la distribution des erreurs correspondent exactement au modèle DCS basé sur la loi de Student- t .

Par conséquent, même pour de faibles valeurs de ν , caractérisées par la présence d'observations extrêmes, le modèle DCS est déjà capable de capturer correctement la structure des données.

TABLE 2.14 – Estimation des paramètres pour KF et DCS. Valeurs initiales : $\sigma_v^2 = 1$, $\sigma_\xi^2 = 0.04$, $\kappa = 0.01$.

N	ν	KF		DCS		
		$\hat{\sigma}_\xi^2$	$\hat{\sigma}_v^2$	$\hat{\sigma}_v^2$	$\hat{\nu}$	κ
5	3	0.009	2.899	1.009	3.10	0.009
5	5	0.000	1.659	1.003	5.16	0.009
5	10	0.000	1.241	0.999	10.63	0.009
5	20	0.000	1.099	1.002	31.08	0.009
5	50	0.000	1.034	1.001	90.57	0.009
20	3	0.004	2.970	1.008	3.05	0.010
20	5	0.002	1.657	1.000	5.11	0.010
20	10	0.002	1.241	1.002	10.33	0.010
20	20	0.002	1.105	1.002	20.95	0.010
20	50	0.002	1.032	1.000	60.63	0.010
40	3	0.012	2.900	1.002	3.04	0.010
40	5	0.003	1.666	1.007	5.09	0.010
40	10	0.003	1.239	0.999	10.24	0.010
40	20	0.003	1.103	1.001	20.63	0.010
40	50	0.003	1.034	1.000	53.57	0.010
60	3	0.005	2.972	1.002	3.04	0.010
60	5	0.004	1.655	1.000	5.06	0.010
60	10	0.004	1.247	1.004	10.20	0.010
60	20	0.004	1.104	1.000	20.73	0.010
60	50	0.004	1.036	1.000	51.51	0.010
100	3	0.008	2.968	1.002	3.04	0.010
100	5	0.006	1.668	1.002	5.04	0.010
100	10	0.006	1.245	1.002	10.23	0.010
100	20	0.005	1.110	1.002	20.27	0.010
100	50	0.005	1.037	0.999	51.18	0.010

Les résultats obtenus montrent que le modèle DCS arrive à une estimation très précise de tous les paramètres, quelles que soient les configurations. Cela peut être vu, en particulier, en considérant le fait que les estimations de σ_v^2 restent très

proches de la valeur réelle ($\sigma_v^2 = 1$), ainsi que le fait que le paramètre ν soit estimé correctement, ce qui suggère que le modèle arrive à une bonne spécification du caractère à queues épaisses des données.

De plus, le paramètre dynamique κ reste estimé de manière stable, tout en restant proche de sa valeur initiale ($\kappa = 0.01$), ce qui suggère que le modèle a bien spécifié sa dynamique.

On voit que les estimations de σ_v^2 obtenues avec le filtre de Kalman sont très proches de la variance effective d'une loi de Student-t. Le filtre de Kalman, qui impose une loi gaussienne, ne capture pas la forme à queues épaisses de la distribution, mais absorbe cette hétérogénéité dans l'estimation de la variance. Ainsi, il tend à estimer une variance proche de la variance effective des données, soit approximativement $\sigma_v^2 \frac{\nu}{\nu-2}$.

Le paramètre σ_ξ^2 est mal estimé. La valeur réelle de σ_ξ^2 est de 0.04. Le filtre de Kalman souvent fournit de basses estimations. La modélisation gaussienne implique la prise en compte d'une grande partie de la variation dans les données dans σ_v^2 , réduisant la variance de l'état.

Chapitre 3

Application aux données de vin

Ce chapitre a pour objectif d’appliquer les modèles développés précédemment à un jeu de données réelles portant sur les vins vendus en supermarchés belges. L’objectif est d’analyser la dynamique des prix à travers un facteur latent, en tenant compte à la fois des caractéristiques observables des produits et des fluctuations non observées.

Dans un premier temps, un modèle hédonique est estimé afin d’expliquer le logarithme des prix en fonction des caractéristiques des vins. Les résidus obtenus représentent alors la partie du prix non expliquée. Dans un second temps, cette composante est modélisée à l’aide de deux approches : le filtre de Kalman, basé sur une hypothèse gaussienne, et le modèle DCS- t , qui permet de prendre en compte d’éventuelles valeurs extrêmes.

L’analyse repose sur un panel non équilibré. Afin d’évaluer la robustesse des modèles, des scénarios de crise sont introduits artificiellement dans les données.

3.1 Description des données

3.1.1 Source des données

Les données utilisées dans cette étude proviennent du secteur de la distribution de vins français vendus dans les supermarchés belges. Elles sont issues de la société *Test Achats*, organisme spécialisé dans l’analyse du marché de la consommation en Belgique, et reflètent des observations réelles du marché du détail.

Ces données ont été mises à disposition dans le cadre du cours par le professeur Christian Hafner, qui a procédé à leur structuration et à leur mise en forme sous la forme d'un fichier exploitable (**wine.xlsx**).

L'utilisation de ces données réelles permet d'appliquer le modèle hédonique dynamique dans un contexte empirique concret, en tenant compte à la fois des caractéristiques intrinsèques des vins et de la dynamique temporelle du marché.

3.1.2 Variables utilisées

Le jeu de données regroupe différentes informations sur les vins, à la fois leurs caractéristiques et leur prix. Pour plus de clarté, les variables sont organisées en trois catégories : la variable dépendante, les variables explicatives qualitatives et les variables explicatives quantitatives.

Variable dépendante La variable d'intérêt est le **prix** du vin.

Variables explicatives qualitatives Plusieurs variables indicatrices permettent de décrire les caractéristiques qualitatives des vins :

- Type de vin : **red**, **white** (référence).
- Région de production : **Bordeaux** (référence), **Loire**, **Rhone**, **Languedoc**, **Bourgogne**, **Alsace**.
- Style ou profil gustatif : **plein charpenté** (référence), **souple et rond**, **riche et puissant**, **léger et fruité**, **sec et épicé**.
- Label : **bio**.

Ces variables permettent de rendre compte des préférences des consommateurs pour certaines catégories de vins.

Variables explicatives quantitatives

- Degré d'alcool (**alcool**) : mesure la teneur en alcool du vin.
- Teneur en sucres (**sucres**) : représente la quantité de sucres résiduels présente dans le vin.
- Acidité (**acidité**) : indique le niveau global d'acidité du vin.
- Acidité volatile (**volatile**) : mesure la présence d'acides volatils pouvant influencer la qualité gustative.

- Acide sorbique (**sorbique**) : concentration en acide sorbique utilisée notamment comme conservateur.
- SO₂ libre (**S02 libre**) : quantité de dioxyde de soufre libre présente dans le vin.
- SO₂ total (**S02 total**) : quantité totale de dioxyde de soufre.
- Note de qualité (**rating**) : variable permettant de capter la qualité perçue du vin.

Dans l'ensemble, ces variables permettent de caractériser les vins à la fois d'un point de vue technique et sensoriel, et sont susceptibles d'exercer une influence significative sur leur prix.

Dimension temporelle La variable **year** correspond au millésime du vin. Elle sert ici à introduire une dimension temporelle dans le modèle, en étant utilisée comme approximation de l'année de transaction, ce qui permet de définir l'effet latent β_t .

3.1.3 Statistiques descriptives

TABLE 3.1 – Nombre d'observations par année.

	2012	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024
Observations	1	1	14	38	75	125	142	124	106	106	109	19
Total : 860												

Le Tableau 3.1 montre que le nombre d'observations change d'une année à l'autre. On voit notamment que les années récentes sont davantage représentées, ce qui peut influencer la précision des estimations dans le temps.

Le Tableau 3.2 présente les principales statistiques descriptives des variables utilisées dans l'analyse.

On observe tout d'abord que le logarithme du prix présente une moyenne de 2.083 et un écart-type de 0.358, ce qui indique une dispersion modérée des prix après transformation logarithmique. Cette transformation permet de réduire l'asymétrie initiale des prix et de stabiliser la variance, comme le confirme la distribution relativement centrée observée à la Figure 3.1a. Les valeurs minimales et maximales (1.095 et 2.791) suggèrent une certaine hétérogénéité dans les prix des vins.

La variable `rating`, qui reflète la qualité perçue des vins, a une moyenne de 71.294 avec un écart-type de 9.061, ce qui montre que la qualité varie sensiblement au sein de l'échantillon.

Les variables physico-chimiques ne présentent pas toutes la même dispersion. Par exemple, le degré d'alcool reste assez proche de sa moyenne (13.39), avec un écart-type relativement faible (0.861), ce qui montre que les vins sont assez homogènes sur ce point.

À l'inverse, certaines variables présentent une variabilité plus importante. C'est notamment le cas des sucres (écart-type de 2.880), ainsi que des concentrations en `SO2 libre` et `SO2 total`, dont les écarts-types sont respectivement de 7.743 et 30.130.

La variable `sorbique` se distingue également par une dispersion particulièrement élevée (écart-type de 23.116), ainsi qu'un intervalle très large entre ses valeurs minimale et maximale. Cela traduit une forte hétérogénéité.

TABLE 3.2 – Statistiques descriptives.

	Moyenne	Écart-type	Min	Max
<code>log(prix)</code>	2.083	0.358	1.095	2.791
<code>rating</code>	71.294	9.061	33.000	90.000
<code>alcool</code>	13.392	0.861	10.500	16.000
<code>sucres</code>	3.235	2.880	1.000	28.000
<code>acidité</code>	5.085	0.680	3.010	8.400
<code>sorbique</code>	24.467	23.116	20.000	182.000
<code>volatile</code>	0.436	0.132	0.130	0.900
<code>SO2 libre</code>	17.631	7.743	0.000	51.000
<code>SO2 total</code>	77.667	30.130	0.000	211.000

La Figure 3.1b présente l'évolution du prix moyen (en logarithme) dans le temps. On observe d'abord une baisse marquée jusqu'en 2017, puis des variations plus faibles par la suite, ce qui laisse penser à une stabilisation des prix sur la période récente.

Les variables qualitatives permettent de caractériser les vins selon leur style, leur origine et certaines caractéristiques spécifiques comme le label `bio`.

On observe que certains styles sont nettement plus représentés, notamment `plein charpenté` et `léger et fruité`, tandis que d'autres restent marginaux.

La répartition des régions apparaît globalement équilibrée entre les principales zones de production. Les fréquences détaillées sont présentées en Annexe A.4.




FIGURE 3.1 – Analyse descriptive du prix des vins.

3.2 Construction du modèle à facteur latent

On cherche d’abord à expliquer le prix des vins à partir de leurs caractéristiques observables, en utilisant un modèle hédonique. Pour cela, on travaille sur le logarithme du prix, ce qui donne :

$$\mathbf{Y}_t = (\log(p_{it}))_{i=1,\dots,N_t} = \mathbf{X}_t \alpha + \mathbf{1}_{N_t} \beta_t + v_t,$$

où $\mathbf{Y}_t$ correspond aux log-prix, $\mathbf{X}_t$ regroupe les variables explicatives, α les coefficients associés, β_t représente un effet commun à toutes les observations à la date t , et v_t correspond aux erreurs.

Une fois cette relation estimée, on s’intéresse à ce qui reste une fois l’effet des variables observables retiré. On définit alors :

$$\mathbf{z}_t = \mathbf{Y}_t - \mathbf{X}_t \hat{\alpha} = \mathbf{1}_{N_t} \beta_t + v_t,$$

qui correspond à la part du prix non expliquée par les caractéristiques observées.

Dans le cadre du filtre de Kalman, on suppose que le facteur latent évolue

progressivement dans le temps selon une marche aléatoire :

$$\beta_t = \beta_{t-1} + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \sigma_\xi^2),$$

et que les erreurs d'observation suivent une loi gaussienne :

$$v_t \sim \mathcal{N}(0, \sigma_v^2 \mathbf{I}_{N_t}).$$

Dans le modèle DCS- t , on suppose que les erreurs suivent une loi de Student :

$$v_t \sim t_\nu(0, \sigma_v^2 \mathbf{I}_{N_t}),$$

et le facteur latent est mis à jour selon une équation basée sur le score :

$$\beta_t = \beta_{t-1} + \kappa u_{t-1}.$$

Les paramètres des deux modèles sont estimés par maximum de vraisemblance.

3.3 Analyse des résultats

Comme l'indiquent les résultats de la régression hédonique présentés dans le Tableau A.2, le prix des vins est significativement influencé par plusieurs caractéristiques. La variable *rating*, qui reflète la qualité perçue, présente un coefficient positif et statistiquement significatif, suggérant qu'une note plus élevée est associée à un prix plus élevé. On observe également des différences marquées de prix selon les régions de production. Comparés aux vins de Bordeaux, les vins de Bourgogne et de la Loire bénéficient d'une prime de prix, alors que ceux du Rhône et du Languedoc se vendent en moyenne moins cher. Les profils descriptifs des vins jouent eux aussi un certain rôle. La catégorie *riche et puissant* est associée à des prix plus élevés, alors que les profils *souple et rond* et *léger et fruité* présentent des effets négatifs par rapport à la catégorie de référence *plein charpenté*. Enfin, certaines caractéristiques physico-chimiques ressortent comme significatives. Le *SO2 libre* est associé à un effet négatif sur le prix, alors que l'effet du *SO2 total* reste positif mais plus limité. Les résultats montrent aussi une prime de prix importante pour les vins *bio*, ce qui laisse penser que ces produits sont particulièrement valorisés par

les consommateurs.

Les résultats d'estimation du Tableau 3.3 montrent des différences marquées entre le filtre de Kalman et le modèle DCS- t . Le filtre de Kalman estime $\hat{\sigma}_\xi^2 = 0,0026$ et $\hat{\sigma}_v^2 = 0,0833$. Les écarts-types correspondants sont assez faibles (0,0020 et 0,0040) ce qui indique que ces estimations sont assez fiables.

Pour le modèle DCS- t , on obtient $\hat{\sigma}_v^2 = 0.0901$, $\hat{\kappa} = 0.00094$ et $\hat{\nu} = 202$. L'estimation de ν est particulièrement élevée, avec un écart-type très important (348.4), ce qui indique une grande incertitude sur ce paramètre.

Ces résultats suggèrent que les données réelles de vins ne présentent pas de comportements extrêmes très marqués. En effet, l'estimation élevée de ν indique que la distribution Student- t se rapproche d'une distribution gaussienne. Le modèle DCS- t ne détecte donc pas de queues épaisses importantes dans les résidus. Par ailleurs, la valeur relativement faible de κ montre que les mises à jour du facteur latent restent modérées au cours du temps. Cela traduit une dynamique relativement stable des prix après prise en compte des caractéristiques hédoniques. On observe également que les estimations de σ_v^2 obtenues avec les deux modèles restent proches, ce qui confirme que les deux approches décrivent une structure de variance similaire dans ce contexte empirique. Ainsi, en absence de fortes valeurs aberrantes, le modèle DCS- t tend naturellement à adopter un comportement proche du filtre de Kalman.

TABLE 3.3 – Résultats d'estimation des modèles KF et DCS- t .

	Paramètre	Estimation	Écart-type
Kalman	σ_ξ^2	0.0026	0.0019
	σ_v^2	0.0832	0.0040
DCS- t	σ_v^2	0.0900	0.0133
	κ	0.0009	0.00016
	ν	202	348.402

Dans le Graphique 3.2(a), on compare $\hat{\beta}_t$ à la moyenne des résidus hédoniques à chaque date, définie par :

$$\bar{z}_t = \frac{1}{N_t} \sum_{i=1}^{N_t} z_{it},$$

on observe que l'estimation du facteur latent β_t obtenue par le filtre de Kalman est très proche de la moyenne des résidus $\bar{z}_t$, ce qui confirme la capacité du modèle

à agréger efficacement l'information contenue dans les données. Le modèle DCS- t produit une trajectoire plus lisse, traduisant une dynamique moins réactive.

Dans le Graphique 3.2(b), on construit un indice de prix à partir du facteur latent estimé :


$$I_t^{KF} = 100 \times \exp(\hat{\beta}_t^{KF} - \hat{\beta}_1^{KF}), \quad I_t^{DCS} = 100 \times \exp(\hat{\beta}_t^{DCS} - \hat{\beta}_1^{DCS}),$$

par ailleurs, un indice de référence basé sur le prix moyen est défini par :

$$I_t^{moy} = 100 \times \exp(\log^-(p)_t - \log^-(p)_1),$$

où $\log^-(p)_t$ désigne le logarithme du prix moyen à la date t .

Les deux indices présentent une évolution assez similaire au cours du temps. Néanmoins, il apparaît que l'indice issu du filtrage de Kalman est moins régulier, contrairement à l'indice du DCS- t .



(a) Comparaison de β_t avec la moyenne des z_t .

(b) Comparaison des indices de prix.

FIGURE 3.2 – Évolution du facteur latent et comparaison des indices estimés par les modèles KF et DCS- t .

3.4 Scénario de crise

3.4.1 Construction du scénario

Afin d'évaluer la robustesse des modèles face aux observations extrêmes, nous introduisons artificiellement des épisodes de crise dans les données. On part de l'ensemble des périodes $\mathcal{T} = \{1, \dots, T\}$. On en sélectionne ensuite aléatoirement une partie pour simuler des années de crise. Cette sélection correspond à une proportion p_T du total, soit $\lfloor p_T T \rfloor$ périodes, regroupées dans l'ensemble $\mathcal{T}_c$.

Pour chaque année $t \in \mathcal{T}_c$, on considère les observations $\{z_{it}\}_{i=1}^{N_t}$ et on sélectionne

aléatoirement un sous-ensemble d'indices $\mathcal{I}_t \subset \{1, \dots, N_t\}$, de taille $|\mathcal{I}_t| = \lfloor p_N N_t \rfloor$, où $p_N \in (0, 1)$ représente la proportion d'observations concernées. Les observations retenues sont alors modifiées de la manière suivante :

$$z_{it}^{\text{crise}} = \begin{cases} z_{it} + s_t \cdot m, & \text{si } i \in \mathcal{I}_t, \\ z_{it}, & \text{sinon,} \end{cases}$$

où $s_t \in \{-1, 1\}$ est un signe tiré aléatoirement (et identique pour une année donnée), et $m > 0$ mesure l'intensité du choc.

3.4.2 Résultats et analyse

Le Tableau 3.4 présente les estimations des paramètres pour différents scénarios de crise, caractérisés par la proportion d'années affectées (p_T), la proportion d'observations perturbées (p_N) et l'intensité du choc (m).

Le filtre de Kalman augmente σ_ξ^2 quand la crise s'intensifie. Par exemple, elle passe de 0.0435 à 0.245 selon les scénarios. On voit donc que la variance d'état devient plus élevée quand les chocs sont plus forts.

Le modèle DCS- t ajuste la distribution des erreurs via le paramètre ν . On constate que ν diminue lorsque la crise devient plus intense, passant d'environ 9.44 à 2.31. Cette baisse indique une augmentation de l'épaisseur des queues de la distribution. On remarque aussi que l'écart-type de ν diminue lorsque les chocs deviennent plus fréquents. C'est assez logique : avec plus d'observations extrêmes, le paramètre est plus facile à estimer, car la log-vraisemblance devient plus sensible à ses variations. En ce qui concerne κ , il augmente généralement avec l'intensité des chocs. Cela signifie que le modèle DCS- t devient plus réactif et s'ajuste plus rapidement aux nouvelles observations.

Quand il y a des chocs, la variance des observations σ_v^2 a tendance à être surestimée dans les deux modèles. Par contre, cette surestimation est moins stable dans le cas du modèle DCS- t , avec des écarts-types plus élevés.

TABLE 3.4 – Résultats d’estimation (avec écarts-types) selon différents scénarios de crise.


p_T	p_N	m	Modèle	Paramètre	Estimation	Écart-type
0.2	0.4	0.8	KF	σ_ξ^2	0.0520	0.0270
				σ_v^2	0.1323	0.0067
			DCS	σ_v^2	0.1037	0.0336
				κ	0.00084	0.00008
				ν	6.95	3.60
0.2	1.0	0.8	KF	σ_ξ^2	0.2239	0.1200
				σ_v^2	0.0832	0.0045
			DCS	σ_v^2	0.1079	0.0645
				κ	0.00165	0.00020
				ν	3.82	2.28
0.3	0.5	0.4	KF	σ_ξ^2	0.0435	0.0244
				σ_v^2	0.0969	0.0047
			DCS	σ_v^2	0.0951	0.0260
				κ	0.00092	0.00019
				ν	9.44	5.20
0.4	0.7	1.0	KF	σ_ξ^2	0.2449	0.1335
				σ_v^2	0.1163	0.0058
			DCS	σ_v^2	0.1217	0.0397
				κ	0.00149	0.00009
				ν	2.31	0.94

La Figure 3.3 montre l’effet de différents scénarios de crise sur l’estimation du facteur latent $\hat{\beta}_t$. Les lignes verticales correspondent aux années où des chocs ont été introduits.


Dans le cas (a), qui correspond à une crise plutôt modérée, les deux modèles donnent des résultats assez similaires en période normale. Par contre, dès qu’un choc apparaît, le filtre de Kalman réagit assez fortement, alors que le modèle DCS- t reste plus stable. Dans le scénario (b), où toutes les observations sont affectées par des chocs extrêmes. Le filtre de Kalman devient alors très volatil, avec des variations parfois excessives, signe d’une forte sensibilité aux valeurs aberrantes. À l’inverse, le modèle DCS- t absorbe mieux ces chocs et conserve une trajectoire beaucoup plus régulière. Lorsque les perturbations sont plus modérées, comme dans le scénario (c),

les deux approches donnent des résultats relativement similaires. Toutefois, le filtre de Kalman reste plus réactif aux petites fluctuations, tandis que le DCS- t conserve un comportement plus lisse. Dans une situation plus sévère comme le cas (d), cette tendance s'accroît : le filtre de Kalman devient clairement instable, avec de fortes oscillations du facteur latent, alors que le modèle DCS- t reste plus robuste et limite mieux l'effet des chocs importants.


Le filtre de Kalman suit fortement les variations observées et devient de plus en plus volatil lorsque l'intensité des chocs augmente. Cette forte réactivité provient du fait que chaque nouvelle observation influence directement la mise à jour du facteur latent. À l'inverse, le modèle DCS- t conserve une trajectoire plus stable et plus régulière. En effet, le terme de pondération ω_t^{-1} réduit l'impact des observations extrêmes sur le score, ce qui limite les ajustements trop brusques du facteur latent. Ainsi, plus les scénarios de crise deviennent sévères, plus la différence entre les deux approches apparaît clairement, mettant en évidence la robustesse du modèle DCS- t face aux perturbations artificielles.




(a) $p_T = 0.2$, $p_N = 0.4$, $m = 0.8$.



(b) $p_T = 0.2$, $p_N = 1$, $m = 0.8$.



(c) $p_T = 0.3$, $p_N = 0.5$, $m = 0.4$.



(d) $p_T = 0.4$, $p_N = 0.7$, $m = 1$.

FIGURE 3.3 – Effet de différents scénarios de crise sur l'estimation du facteur latent. Les lignes verticales indiquent les années de choc.

3.5 Limites des données

Malgré l'intérêt du jeu de données utilisé, certaines limites doivent être soulignées.

Il faut d'abord garder en tête que la période observée est assez courte. Le nombre d'années disponibles reste limité, ce qui rend plus difficile l'analyse des dynamiques de long terme et peut aussi jouer sur la précision des estimations.

Ensuite, le panel est non équilibré, ce qui signifie que le nombre d'observations varie d'une année à l'autre. Cette hétérogénéité peut également influencer la précision des estimations. En particulier pour les années où peu de données sont disponibles.

Un autre point concerne l'utilisation de la variable `year`. Elle est prise comme une approximation de la date de transaction, alors qu'elle correspond en réalité au millésime, ce qui peut introduire un biais dans l'interprétation temporelle des résultats.

Enfin, les données ne présentent pas naturellement de valeurs aberrantes marquées. Afin d'évaluer la robustesse des modèles, des scénarios de crise ont été introduits artificiellement, ce qui constitue une approximation du comportement réel du marché.

Ces éléments invitent à interpréter les résultats avec prudence.

Conclusion

Ce mémoire avait pour objectif d’étudier la construction d’indices de prix hédoniques dynamiques à l’aide de modèles espace-état, en comparant deux approches d’estimation : le filtre de Kalman et les modèles score-driven de type DCS- t .

Le travail a d’abord consisté à mettre en place un modèle hédonique dynamique dans lequel un facteur latent commun varie au fil du temps. Cette formulation permet de mieux tenir compte des évolutions du marché que les modèles hédoniques classiques reposant sur des coefficients fixes. L’étude s’est ensuite portée sur le filtre de Kalman multivarié sous hypothèse gaussienne. À travers les simulations Monte Carlo, nous avons observé que cette approche conduit à des estimations précises et globalement peu biaisées, aussi bien pour l’état latent que pour les paramètres du modèle. Les simulations indiquent également que la dimension transversale N a un effet non négligeable : l’augmentation du nombre d’observations diminue de façon importante la variance et la MSE associée à l’estimation de l’état latent β_t . Quant à la dimension temporelle T , elle améliore surtout la précision des estimateurs des paramètres σ_ξ^2 et σ_v^2 tandis que son effet sur la MSE de l’état latent s’avère plus limité lorsque le filtre a été stabilisé.

Dans un second temps, nous avons introduit le modèle DCS- t , fondé sur une distribution de Student- t , afin de mieux prendre en compte les observations extrêmes et les distributions à queues épaisses. Les résultats obtenus montrent que cette approche est plus robuste face aux chocs et aux valeurs atypiques. En présence de crises ou de contaminations artificielles des données, le filtre de Kalman tend à réagir fortement en augmentant les estimations des variances afin d’absorber les observations extrêmes. À l’inverse, le modèle DCS- t parvient à limiter l’impact de ces

observations grâce à la présence du terme de pondération associé à la distribution de Student- t .

Finalement, l'application à des données réelles sur les vins a permis d'évaluer les deux méthodes dans un cadre empirique. Les résultats obtenus démontrent que l'utilisation de modèles dynamiques est utile pour analyser l'évolution temporelle des prix hédoniques et une meilleure représentation des fluctuations du marché. Il ressort également de ces résultats que certaines variables, telles que la localisation de production, la nature du vin ou la qualité, ont un impact significatif sur les prix. Ces résultats restent toutefois à nuancer en raison de plusieurs limites. La dimension temporelle des données demeure relativement courte, ce qui peut réduire la précision des estimations dynamiques. Par ailleurs, la variable temporelle utilisée correspond à une approximation de la date réelle des transactions. Enfin, les modèles étudiés reposent sur une structure relativement simple du facteur latent.

Les simulations ont également mis en évidence une limite potentielle du modèle DCS- t lorsque la dimension transversale N devient très grande. Les résultats présentés en Annexe (A.7) montrent que la variance du κu_t , augmentent approximativement de manière linéaire avec la taille du panel. Cette propriété peut rendre les mises à jour du facteur latent excessivement volatiles dans les grands panels et conduire à une dynamique plus instable. À l'inverse, le filtre de Kalman ajuste automatiquement son gain en fonction du nombre d'observations, ce qui lui permet de conserver une dynamique plus stable lorsque N augmente. Une extension naturelle consisterait à introduire un paramètre de mise à jour dépendant de la taille du panel, par exemple via une normalisation de type $\kappa_N = c/\sqrt{N}$. Une telle approche permettrait de limiter la croissance de la variance du terme de mise à jour lorsque N devient grand et pourrait améliorer la stabilité asymptotique du modèle DCS- t .

Plusieurs extensions pourraient être envisagées dans de futurs travaux. Il serait notamment intéressant d'introduire plusieurs facteurs latents, des dynamiques plus complexes ou encore des distributions asymétriques afin de mieux représenter certaines caractéristiques des données économiques et financières.

Ce travail montre dans l'ensemble que les modèles dynamiques sont un outil pertinent pour la construction d'indices de prix hédoniques et que les approches score-driven sont une alternative robuste aux méthodes gaussiennes classiques lorsque les données présentent des comportements extrêmes.

Annexe A

Annexes

A.1 Démonstration des équations du filtre de Kalman

La dérivation des équations du filtre de Kalman présentée dans cette section s'inspire notamment du tutoriel de Tony LACEY [1998](#).

On considère le modèle suivant :

$$\beta_t = \beta_{t-1} + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \sigma_\xi^2),$$

$$\mathbf{z}_t = \mathbf{1}_N \beta_t + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_v^2 I_N),$$

où $\mathbf{z}_t \in R^{N \times 1}$, $\mathbf{1}_N \in R^{N \times 1}$ désigne le vecteur colonne de 1, et $\beta_t \in R$ est un état latent scalaire.

On note $\beta_{t|t-1}$ l'estimation prédite de β_t , et $\beta_{t|t}$ son estimation filtrée après observation.

Étape 1 : covariance de l'innovation

La covariance de l'innovation est donc :

$$S_t = E(\mathbf{v}_t \mathbf{v}_t^\top),$$

avec

$$\mathbf{v}_t = \mathbf{z}_t - \mathbf{1}_N \beta_{t|t-1} = \mathbf{1}_N (\beta_t - \beta_{t|t-1}) + v_t.$$

En développant :

$$S_t = E \left[\left(\mathbf{1}_N (\beta_t - \beta_{t|t-1}) + v_t \right) \left(\mathbf{1}_N (\beta_t - \beta_{t|t-1}) + v_t \right)^\top \right].$$

$$S_t = \mathbf{1}_N E \left[(\beta_t - \beta_{t|t-1})^2 \right] \mathbf{1}_N^\top + E(v_t v_t^\top).$$

Par définition :

$$E \left[(\beta_t - \beta_{t|t-1})^2 \right] = P_{t|t-1}, \quad E(v_t v_t^\top) = \sigma_v^2 I_N.$$

On obtient donc :

$$\boxed{S_t = \mathbf{1}_N P_{t|t-1} \mathbf{1}_N^\top + \sigma_v^2 I_N.}$$

Étape 2 : covariance de l'erreur filtrée

La variance de l'erreur filtrée est alors :

$$P_{t|t} = E \left[(\beta_t - \beta_{t|t})^2 \right].$$

En remplaçant $\beta_{t|t}$:

$$\beta_t - \beta_{t|t} = \beta_t - \beta_{t|t-1} - K_t \left(z_t - \mathbf{1}_N \beta_{t|t-1} \right) = \beta_t - \beta_{t|t-1} - K_t \left(\mathbf{1}_N (\beta_t - \beta_{t|t-1}) + v_t \right).$$

En factorisant :

$$\beta_t - \beta_{t|t} = (1 - K_t \mathbf{1}_N) (\beta_t - \beta_{t|t-1}) - K_t v_t,$$

$$P_{t|t} = E \left[\left((1 - K_t \mathbf{1}_N) (\beta_t - \beta_{t|t-1}) - K_t v_t \right)^2 \right].$$

Comme $\beta_t - \beta_{t|t-1}$ et v_t sont décorrélés, les termes croisés disparaissent. On

obtient donc :

$$P_{t|t} = (1 - K_t 1_N)^2 E[(\beta_t - \beta_{t|t-1})^2] + K_t E(v_t v_t^\top) K_t^\top.$$

On obtient donc :

$$\boxed{P_{t|t} = (1 - K_t 1_N)^2 P_{t|t-1} + \sigma_v^2 K_t K_t^\top.}$$

Étape 3 : détermination du gain optimal

On choisit K_t de manière à minimiser $P_{t|t}$. En développant l'expression précédente :

$$P_{t|t} = P_{t|t-1} - 2K_t 1_N P_{t|t-1} + K_t 1_N 1_N^\top K_t^\top P_{t|t-1} + \sigma_v^2 K_t K_t^\top.$$

On peut réécrire cela sous la forme :

$$P_{t|t} = P_{t|t-1} - 2K_t 1_N P_{t|t-1} + K_t (P_{t|t-1} 1_N 1_N^\top + \sigma_v^2 I_N) K_t^\top.$$

Comme

$$S_t = P_{t|t-1} 1_N 1_N^\top + \sigma_v^2 I_N,$$

il vient

$$P_{t|t} = P_{t|t-1} - 2K_t 1_N P_{t|t-1} + K_t S_t K_t^\top.$$

On dérive cette expression :

$$\frac{\partial}{\partial K_t} (P_{t|t}) = 0 \quad \Rightarrow \quad -2P_{t|t-1} I_N^\top + 2K_t S_t = 0,$$

on trouve :

$$\boxed{K_t = P_{t|t-1} 1_N^\top S_t^{-1},}$$

avec

$$K_t S_t K_t^\top = K_t 1_N P_{t|t-1}.$$

Ainsi

$$P_{t|t} = P_{t|t-1} - 2K_t 1_N P_{t|t-1} + K_t 1_N P_{t|t-1},$$

$$\boxed{P_{t|t} = (1 - K_t 1_N) P_{t|t-1}.}$$

En utilisant la formule de Sherman–Morrison :

$$\left(P_{t|t-1}1_N1_N^\top + \sigma_v^2 I_N\right)^{-1} 1_N = \frac{1}{\sigma_v^2 + NP_{t|t-1}} 1_N.$$

On en déduit :

$$K_t = \frac{P_{t|t-1}}{\sigma_v^2 + NP_{t|t-1}} 1_N^\top,$$

$$P_{t|t} = \frac{P_{t|t-1}\sigma_v^2}{\sigma_v^2 + NP_{t|t-1}}.$$

A.2 État stationnaire du filtre de Kalman

On a

$$P_{t|t-1} = P_{t-1|t-1} + \sigma_\xi^2,$$

et

$$P_{t|t} = \frac{\sigma_v^2 P_{t|t-1}}{\sigma_v^2 + NP_{t|t-1}}.$$

En combinant les deux expressions, on obtient

$$P_{t|t} = \frac{\sigma_v^2 (P_{t-1|t-1} + \sigma_\xi^2)}{\sigma_v^2 + N(P_{t-1|t-1} + \sigma_\xi^2)}.$$

À l'état stationnaire, on pose :

$$P_{t|t} = P_{t-1|t-1} = P_{\infty|\infty},$$

ce qui conduit à :

$$P_{\infty|\infty} = \frac{\sigma_v^2 (P_{\infty|\infty} + \sigma_\xi^2)}{\sigma_v^2 + N(P_{\infty|\infty} + \sigma_\xi^2)}.$$

Après simplification, on obtient l'équation quadratique :

$$P_{\infty|\infty}^2 + \sigma_\xi^2 P_{\infty|\infty} - \frac{\sigma_v^2 \sigma_\xi^2}{N} = 0,$$

dont la solution positive est :

$$P_{\infty|\infty} = \frac{-\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_v^2\sigma_{\xi}^2}{N}}}{2}.$$

Lorsque $t \rightarrow \infty$, le gain de Kalman converge vers une constante K_{∞} donnée par :

$$K_{\infty} = \frac{P_{\infty|\infty-1}}{\sigma_v^2 + NP_{\infty|\infty-1}},$$

où

$$P_{\infty|\infty-1} = P_{\infty|\infty} + \sigma_{\xi}^2,$$

on obtient également :

$$K_{\infty} = \frac{\frac{\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_v^2\sigma_{\xi}^2}{N}}}{2}}{\sigma_v^2 + N \cdot \frac{\sigma_{\xi}^2 + \sqrt{\sigma_{\xi}^4 + \frac{4\sigma_v^2\sigma_{\xi}^2}{N}}}{2}} \mathbf{1}_N^{\top}.$$

A.3 Démonstration du modèle DCS- t

Le score est obtenu en dérivant la log-densité par rapport au facteur latent β_t :

$$u_t = \frac{\partial \log f_t(\mathbf{z}_t; \theta)}{\partial \beta_t}.$$

On pose :

$$\omega_t = 1 + \frac{\mathbf{e}_t^{\top} \mathbf{e}_t}{\nu \sigma_v^2}.$$

Ainsi,

$$\log f_t(\mathbf{z}_t; \theta) = \log \Gamma\left(\frac{\nu + N}{2}\right) - \log \Gamma\left(\frac{\nu}{2}\right) - \frac{N}{2} \log(\nu \pi \sigma_v^2) - \frac{\nu + N}{2} \log(\omega_t).$$

On a :

$$\mathbf{e}_t = \mathbf{z}_t - \mathbf{1}_N \beta_t,$$

donc :

$$\frac{\partial \mathbf{e}_t}{\partial \beta_t} = -\mathbf{1}_N.$$

On a alors :

$$\frac{\partial}{\partial \beta_t} (\mathbf{e}_t^\top \mathbf{e}_t) = -2\mathbf{1}_N^\top \mathbf{e}_t.$$

Par conséquent,

$$\frac{\partial \omega_t}{\partial \beta_t} = -\frac{2}{\nu \sigma_v^2} \mathbf{1}_N^\top \mathbf{e}_t.$$

En dérivant la log-densité, on obtient :

$$u_t = -\frac{\nu + N}{2} \frac{1}{\omega_t} \frac{\partial \omega_t}{\partial \beta_t}.$$

En remplaçant $\frac{\partial \omega_t}{\partial \beta_t}$, il vient :

$$u_t = -\frac{\nu + N}{2} \frac{1}{\omega_t} \left(-\frac{2}{\nu \sigma_v^2} \mathbf{1}_N^\top \mathbf{e}_t \right).$$

Après simplification :

$$u_t = \frac{1}{\omega_t} \frac{\nu + N}{\nu} \frac{1}{\sigma_v^2} \mathbf{1}_N^\top \mathbf{e}_t$$

avec :

$$\omega_t = 1 + \frac{\mathbf{e}_t^\top \mathbf{e}_t}{\nu \sigma_v^2}.$$

La dynamique du modèle DCS- t est ensuite donnée par :

$$\beta_t = \beta_{t-1} + \kappa u_{t-1}.$$

A.4 Fréquences des variables qualitatives

TABLE A.1 – Fréquences des variables qualitatives.

Variable	Nombre	Pourcentage (%)
bio	119	13.84
plein charpenté	363	42.21
souple et rond	183	21.28
riche et puissant	58	6.74
léger et fruité	244	28.37
sec et épicé	12	1.40
Bordeaux	206	23.95
Loire	74	8.60
Rhone	176	20.47
Languedoc	176	20.47
Bourgogne	148	17.21
Alsace	80	9.30

A.5 Résultats de la régression hédonique

TABLE A.2 – Résultats de la régression hédonique – Variable dépendante : $\log(\text{price})$.

Variable	Coeff.	Std Err	t	P> t	[0.025	0.975]
const	0.0693	0.280	0.247	0.805	-0.480	0.619
rating	0.0040	0.001	3.197	0.001	0.002	0.006
red	-0.0912	0.045	-2.042	0.041	-0.179	-0.004
Loire	0.2145	0.054	3.987	0.000	0.109	0.320
Rhone	-0.1014	0.035	-2.914	0.004	-0.170	-0.033
Languedoc	-0.1567	0.035	-4.510	0.000	-0.225	-0.088
Bourgogne	0.3549	0.037	9.479	0.000	0.281	0.428
Alsace	0.0752	0.056	1.337	0.181	-0.035	0.186
alcool	0.1282	0.017	7.479	0.000	0.095	0.162
sucres	0.0073	0.005	1.572	0.116	-0.002	0.016
acidité	0.0106	0.019	0.561	0.575	-0.026	0.048
volatile	0.1406	0.114	1.232	0.218	-0.083	0.365
sorbique	0.0003	0.000	0.586	0.558	-0.001	0.001
SO2 libre	-0.0122	0.002	-6.672	0.000	-0.016	-0.009
SO2 total	0.0015	0.001	2.530	0.012	0.000	0.003
souple et rond	-0.0810	0.030	-2.721	0.007	-0.139	-0.023
riche et puissant	0.1030	0.044	2.369	0.018	0.018	0.188
léger et fruité	-0.0824	0.031	-2.693	0.007	-0.142	-0.022
sec et épicé	-0.0441	0.094	-0.470	0.639	-0.228	0.140
bio	0.1610	0.032	5.068	0.000	0.099	0.223

A.6 Convergence du gain de Kalman











(a) $N = 90$.(b) $N = 80$.(c) $N = 60$.(d) $N = 50$.(e) $N = 40$.(f) $N = 30$.(g) $N = 20$.(h) $N = 10$.


FIGURE A.1 – Convergence du gain de Kalman pour différentes tailles de panel N et $\nu=10000$, β_t est généré par une marché aléatoire.




(a) $N = 100$.




(b) $N = 80$.



(c) $N = 60$.



(d) $N = 30$.



(e) $N = 10$.

FIGURE A.2 – Convergence du gain de Kalman pour différentes tailles de panel N et $\nu=10000$, β_t est généré par une dynamique DCS.

A.7 Limite asymptotique DCS pour grands N




FIGURE A.3 – Evolution de $\text{var}(\kappa u_t)$ avec N .

Bibliographie

- [1] L. BENFRATELLO, M. PIACENZA et S. SACCHETTO. “Taste or Reputation: What Drives Market Prices in the Wine Industry? Estimation of a Hedonic Model for Italian Premium Wines”. In : *Applied Economics* 41.17 (2009), p. 2197-2209.
- [2] F. Y. BOCART et C. M. HAFNER. “Fair Revaluation of Wine as an Investment”. In : *Journal of Wine Economics* 10.2 (2015), p. 190-203.
- [3] F. Y. BOCART et C. M. HAFNER. “Volatility of price indices for heterogeneous goods with applications to the fine art market”. In : *Journal of Applied Econometrics* 30.2 (2015), p. 291-312.
- [4] J.-M. CARDEBAT et J.-M. FIGUET. “Estimation of a Hedonic Price Equation for Alsace, Beaujolais and Provence Wines”. In : *Applied Economics Letters* 16.9 (2009), p. 921-927.
- [5] J.-M. CARDEBAT et J.-M. FIGUET. “What Explains Bordeaux Wine Prices?” In : *Applied Economics Letters* 11.5 (2004), p. 293-296.
- [6] P. COMBRIS, S. LECOCQ et M. VISSER. “Estimation of a Hedonic Price Equation for Bordeaux Wine: Does Quality Matter?” In : *The Economic Journal* 107.441 (1997), p. 390-402.
- [7] P. COMBRIS, S. LECOCQ et M. VISSER. “Estimation of a Hedonic Price Equation for Burgundy Wine”. In : *Applied Economics* 32.8 (2000), p. 961-967.
- [8] A. CORSI et S. STROM. “The Price Premium for Organic Wines: Estimating a Hedonic Farm-Gate Price Equation”. In : *Journal of Wine Economics* 8.1 (2013), p. 29-48.

- [9] A. COURT. “Hedonic Price Indexes with Automotive Examples”. In : *The Dynamics of Automobile Demand* (1939).
- [10] D. CREAL, S. J. KOOPMAN et A. LUCAS. “Generalized autoregressive score models with applications”. In : *Journal of Applied Econometrics* 28.5 (2013), p. 777-795.
- [11] J. DURBIN et S. J. KOOPMAN. *Time Series Analysis by State Space Methods*. Oxford University Press, 2012.
- [12] Z. GRILICHES. “Hedonic Price Indexes for Automobiles”. In : *NBER* (1961).
- [13] C. M. HAFNER. “Explanatory Factors of French Retail Wine Prices”. In : *Applied Economics Letters* (2023).
- [14] A. C. HARVEY. *Dynamic Models for Volatility and Heavy Tails*. Cambridge University Press, 2013.
- [15] A. C. HARVEY. *Forecasting, Structural Time Series Models and the Kalman Filter*. Cambridge University Press, 1989.
- [16] G. V. JONES et K.-H. STORCHMANN. “Wine Market Prices and Investment under Uncertainty: An Econometric Model for Bordeaux Crus Classes”. In : *Agricultural Economics* 26 (2001), p. 115-133.
- [17] R. E. KALMAN. “A new approach to linear filtering and prediction problems”. In : *Journal of Basic Engineering* 82.1 (1960), p. 35-45.
- [18] R. E. KALMAN et R. S. BUCY. “New results in linear filtering and prediction theory”. In : *Journal of Basic Engineering* 83.1 (1961), p. 95-108.
- [19] T. LACEY. *Tutorial: The Kalman Filter*. Chapter 11. 1998.
- [20] M.-B. LIN, B. WANG, F. Y. R. P. BOCART, C. M. HAFNER et W. K. HARDLE. “DAI Digital Art Index: A Robust Price Index for Heterogeneous Digital Assets”. Working paper. 2025.
- [21] Y. NISHIYAMA. “Wine Quality and Pricing in the Global Wine Export Market: The Case of Chilean Wines”. In : *Applied Economics Letters* 30.7 (2023), p. 986-990.
- [22] J. NOCEDAL et S. J. WRIGHT. *Numerical Optimization*. 2^e éd. Springer, 2006.
- [23] J.-F. OUTREVILLE et E. LE FUR. “Hedonic Price Functions and Wine Price Determinants: A Review of Empirical Research”. In : *Journal of Agricultural and Food Industrial Organization* 18.2 (2020), p. 20190028.

- [24] J. REBELO, L. LOURENCO-GOMES, T. GONCALVES et J. CALDAS. “A Hedonic Price Analysis for the Portuguese Wine Market: Does the Distribution Channel Matter?” In : *Journal of Applied Economics* 22.1 (2019), p. 40-59.
- [25] S. ROSEN. “Hedonic Prices and Implicit Markets”. In : *Journal of Political Economy* (1974).
- [26] D. SIMON. *Optimal State Estimation*. Wiley, 2006.
- [27] F. V. WAUGH. “Quality Factors Influencing Vegetable Prices”. In : *Journal of Farm Economics* (1928).

