

Comparaison du filtre de Kalman et des modèles score-driven pour la construction d'indices de prix hédoniques dynamiques

Yassine Zeamari

13 septembre 2026

Université Catholique de louvain / Faculté des sciences
Master [120] en science des données, orientation statistique

Problématique et objectif

Contexte. Les prix des biens dépendent de caractéristiques observables, mais aussi d'une composante commune du marché qui évolue dans le temps et qui n'est pas directement observable.

Problématique. Comment construire un indice de prix hédonique dynamique, tout en tenant compte de la présence possible de valeurs extrêmes ?

Objectif. Comparer deux méthodes d'estimation d'un facteur latent dynamique :

Filtre de Kalman vs DCS- t .

- Simulations Monte Carlo ;
- Application aux données de vins.

Pourquoi un indice hédonique dynamique ?

Biens hétérogènes

Certains biens ne sont pas directement comparables entre eux, car leur prix dépend de nombreuses caractéristiques observables.

Modèle hédonique

Le modèle hédonique, introduit notamment par WAUGH (1928) et COURT (1939), ROSEN (1974) permet de séparer l'effet des caractéristiques observables de la composante commune du marché :

$$Y_t = X_t \alpha + 1_N \beta_t + v_t,$$

Indice dynamique

Le facteur latent β_t représente l'évolution générale du prix au cours du temps, après correction des caractéristiques observables.

Filtre de Kalman : modèle espace-état

$$\beta_t = \beta_{t-1} + \xi_t, \quad \xi_t \sim \mathcal{N}(0, \sigma_\xi^2)$$

$$z_t = 1_N \beta_t + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_v^2 I_N)$$

- β_t : état latent dynamique ;
- z_t : observations à la date t ;
- σ_ξ^2 : variance du bruit d'état ;
- σ_v^2 : variance du bruit d'observation.

Filtre de Kalman : récursions

Référence : (KALMAN 1960 ; DURBIN et KOOPMAN 2012)

Étape de prédiction

$$\beta_{t|t-1} = \beta_{t-1|t-1}, \quad P_{t|t-1} = P_{t-1|t-1} + \sigma_{\xi}^2$$

Étape de correction

$$\mathbf{v}_t = \mathbf{z}_t - \mathbf{1}_N \beta_{t|t-1}, \quad \mathbf{v}_t \in \mathbb{R}^{N \times 1}, \quad (1)$$

$$\mathbf{S}_t = \mathbf{1}_N P_{t|t-1} \mathbf{1}_N^{\top} + \sigma_v^2 I_N, \quad \mathbf{S}_t \in \mathbb{R}^{N \times N}, \quad (2)$$

$$\mathbf{K}_t = P_{t|t-1} \mathbf{1}_N^{\top} \mathbf{S}_t^{-1} = \frac{P_{t|t-1}}{\sigma_v^2 + N P_{t|t-1}} \mathbf{1}_N^{\top}, \quad \mathbf{K}_t \in \mathbb{R}^{1 \times N}, \quad (3)$$

$$\beta_{t|t} = \beta_{t|t-1} + \mathbf{K}_t \mathbf{v}_t, \quad \beta_{t|t} \in \mathbb{R}, \quad (4)$$

$$P_{t|t} = (1 - \mathbf{K}_t \mathbf{1}_N) P_{t|t-1} = \frac{P_{t|t-1} \sigma_v^2}{\sigma_v^2 + N P_{t|t-1}}, \quad P_{t|t} \in \mathbb{R}. \quad (5)$$

Résultat Kalman : effet du nombre d'observations

Simulation Monte Carlo

Pour chaque configuration, $MC = 500$ trajectoires sont simulées. La vraie trajectoire β_t est connue, ce qui permet de calculer la MSE, le biais et la variance.




Figure 1 – Évolution de la MSE de l'estimation de β_t en fonction de la taille du panel N .

Résultat Kalman : la taille temporelle T

T	Bias	Var	MSE
20	0.0015	0.01283	0.01283
50	0.0005	0.01274	0.01274
100	-0.0001	0.01264	0.01265
150	-0.0002	0.01269	0.01269
200	0.0002	0.01260	0.01260
300	0.0001	0.01267	0.01267
400	0.0001	0.01264	0.01264
600	0.0002	0.01265	0.01265
800	0.0001	0.01267	0.01267
1000	-0.0002	0.01266	0.01266

Table 1 – Impact de la dimension temporelle T sur les performances de l'estimation de β_t pour un panel de taille fixée $N = 60$ (MC = 500).

Idée principale

Le modèle DCS- t met à jour l'état latent à partir du score de la densité conditionnelle
CREAL, KOOPMAN et LUCAS (2013) et HARVEY (2013) :

$$u_t = \frac{\partial \log f_t(z_t; \theta)}{\partial \beta_t}$$

$$\mathbf{e}_t = \mathbf{z}_t - \mathbf{1}_N \beta_t, \quad (6)$$

$$\beta_t = \beta_{t-1} + \kappa u_{t-1}, \quad (7)$$

$$u_t = \frac{1}{\omega_t} \frac{\nu + N}{\nu} \frac{1}{\sigma_v^2} \mathbf{1}_N' \mathbf{e}_t, \quad (8)$$

$$\omega_t = 1 + \frac{\mathbf{e}_t' \mathbf{e}_t}{\nu \sigma_v^2}. \quad (9)$$

Terme de pondération

$$\omega_t = 1 + \frac{e_t' e_t}{\nu \sigma_v^2}$$

Interprétation

- si les résidus sont faibles, ω_t reste proche de 1 ;
- si les résidus sont grands, ω_t augmente ;
- donc $\frac{1}{\omega_t}$ diminue ;
- les observations extrêmes ont moins d'influence sur la mise à jour.

$$e_t' e_t \uparrow \implies \omega_t \uparrow \implies u_t \downarrow$$

Design de simulation Monte Carlo

Principe

Pour chaque configuration, $MC = 500$ trajectoires sont simulées. La vraie trajectoire β_t est connue.

$$\beta_t \rightarrow \mathbf{z}_t \rightarrow \hat{\beta}_t^{KF}, \hat{\beta}_t^{DCS}$$

Mesures de performance

$$MSE = Variance + Bias^2$$

- MSE : erreur globale ;
- biais : erreur systématique ;
- variance : instabilité de l'estimation.

Résultats des simulations

- État latent généré par Marche aléatoire avec erreurs Student- t : Kalman reste performant lorsque la dynamique de l'état latent est bien spécifiée.

Table 2 – État latent généré par Marche aléatoire avec erreurs Student- t : résultats clés

N	ν	MSE KF	MSE DCS
5	3	0.148	0.134
5	10	0.082	0.118
5	50	0.075	0.114
20	3	0.061	0.083
20	50	0.030	0.070
40	5	0.026	0.067
40	50	0.018	0.058
60	10	0.015	0.058
100	3	0.021	0.066
100	50	0.009	0.051

Résultats des simulations

- État latent généré par DCS- t : DCS- t obtient les meilleures performances lorsque la vraie dynamique est score-driven.

Table 3 – État latent généré par DCS- t : résultats clés

N	ν	MSE KF	MSE DCS
5	3	0.01633	0.00152
5	50	0.00166	0.00123
20	3	0.01027	0.00031
20	50	0.00183	0.00031
40	3	0.01546	0.00015
40	50	0.00256	0.00014
60	3	0.00871	0.00009
100	3	0.00871	0.00005
100	50	0.00346	0.00005

Scénario de crise : l'état latent suit une marche aléatoire, tandis que la crise est simulée par une augmentation temporaire de la variance des erreurs d'observation :

$$\sigma_t^2 = \begin{cases} \sigma_v^2, & \text{régime normal,} \\ m^2 \sigma_v^2, & \text{régime de crise.} \end{cases}$$

Table 4 – Scénario de crise : résultats clés

N	ν	MSE KF	MSE DCS
5	3	3.157	0.254
5	50	0.817	0.198
20	3	0.726	0.105
40	5	0.289	0.087
60	10	0.188	0.079
100	50	0.123	0.075

Données empiriques

- 860 observations de vins vendus en supermarchés belges ;
- caractéristiques : région, type, profil, label bio, rating, variables physico-chimiques ;
- panel non équilibré : le nombre d'observations varie selon l'année.

Modèle hédonique

$$Y_t = (\log(p_{it}))_{i=1,\dots,N_t} = X_t \alpha + 1_{N_t} \beta_t + v_t,$$

$$z_t = Y_t - X_t \hat{\alpha} = 1_{N_t} \beta_t + v_t$$

Objectif

Estimer la composante latente β_t après correction des caractéristiques observables.

Résultats empiriques : Kalman vs DCS- t

Modèle	Paramètre	Est.
KF	σ_{ξ}^2	0.0026
KF	σ_v^2	0.0832
DCS- t	σ_v^2	0.0900
DCS- t	κ	0.0009
DCS- t	ν	202

- $\hat{\nu}$ élevé : données proches du cadre gaussien ;
- κ faible : dynamique DCS plus lisse ;
- variances proches entre KF et DCS.




Figure 2 – Comparaison des indices de prix.

Résultats principaux

- Kalman est efficace dans un cadre gaussien stable.
- DCS- t est plus robuste face aux valeurs extrêmes.
- Sur les données réelles, $\hat{\nu}$ est élevé : comportement proche du gaussien.

Limites

- données courtes et nombre d'observations faible pour certaines années ;
- year utilisé comme proxy temporel ;
- DCS- t peut nécessiter une normalisation lorsque N devient grand.

Extensions

- plusieurs facteurs latents ;
- distributions asymétriques ou modèles à changement de régime.

Références

-  COURT, A. (1939). **“Hedonic Price Indexes with Automotive Examples”**. In : *The Dynamics of Automobile Demand*.
-  CREAL, D., S. J. KOOPMAN et A. LUCAS (2013). **“Generalized autoregressive score models with applications”**. In : *Journal of Applied Econometrics* 28.5, p. 777-795.
-  DURBIN, J. et S. J. KOOPMAN (2012). ***Time Series Analysis by State Space Methods***. Oxford University Press.
-  HARVEY, A. C. (2013). ***Dynamic Models for Volatility and Heavy Tails***. Cambridge University Press.
-  KALMAN, R. E. (1960). **“A new approach to linear filtering and prediction problems”**. In : *Journal of Basic Engineering* 82.1, p. 35-45.
-  ROSEN, S. (1974). **“Hedonic Prices and Implicit Markets”**. In : *Journal of*

Merci pour votre attention

Questions ?

Yassine Zeamari